UdeA
Analytics &
DataScience

DATA STREAMING Y SERVICIOS EN LA NUBE

INTRODUCCIÓN

Magister - Efraín Alberto Oviedo
alberto.oviedo@udea.edu.co

UNIVERSIDAD DE ANTIOQUIA
FACULTAD DE INGENIERÍA
ESPECIALIZACIÓN EN ANALÍTICA Y CIENCIA DE DATOS

UNIVERSIDAD DE ANTIOQUIA
1 8 0 3

AGENDA

UdeA
Analytics & DataScience

1. **Contexto**
2. Procesamiento de Datos
3. Cloud Computing
4. Aplicaciones

Inteligencia de Negocios

https://nexusintegra.io/es/business-intelligence-industria-inteligencia-negocio/

Inteligencia de Negocios Tradicional

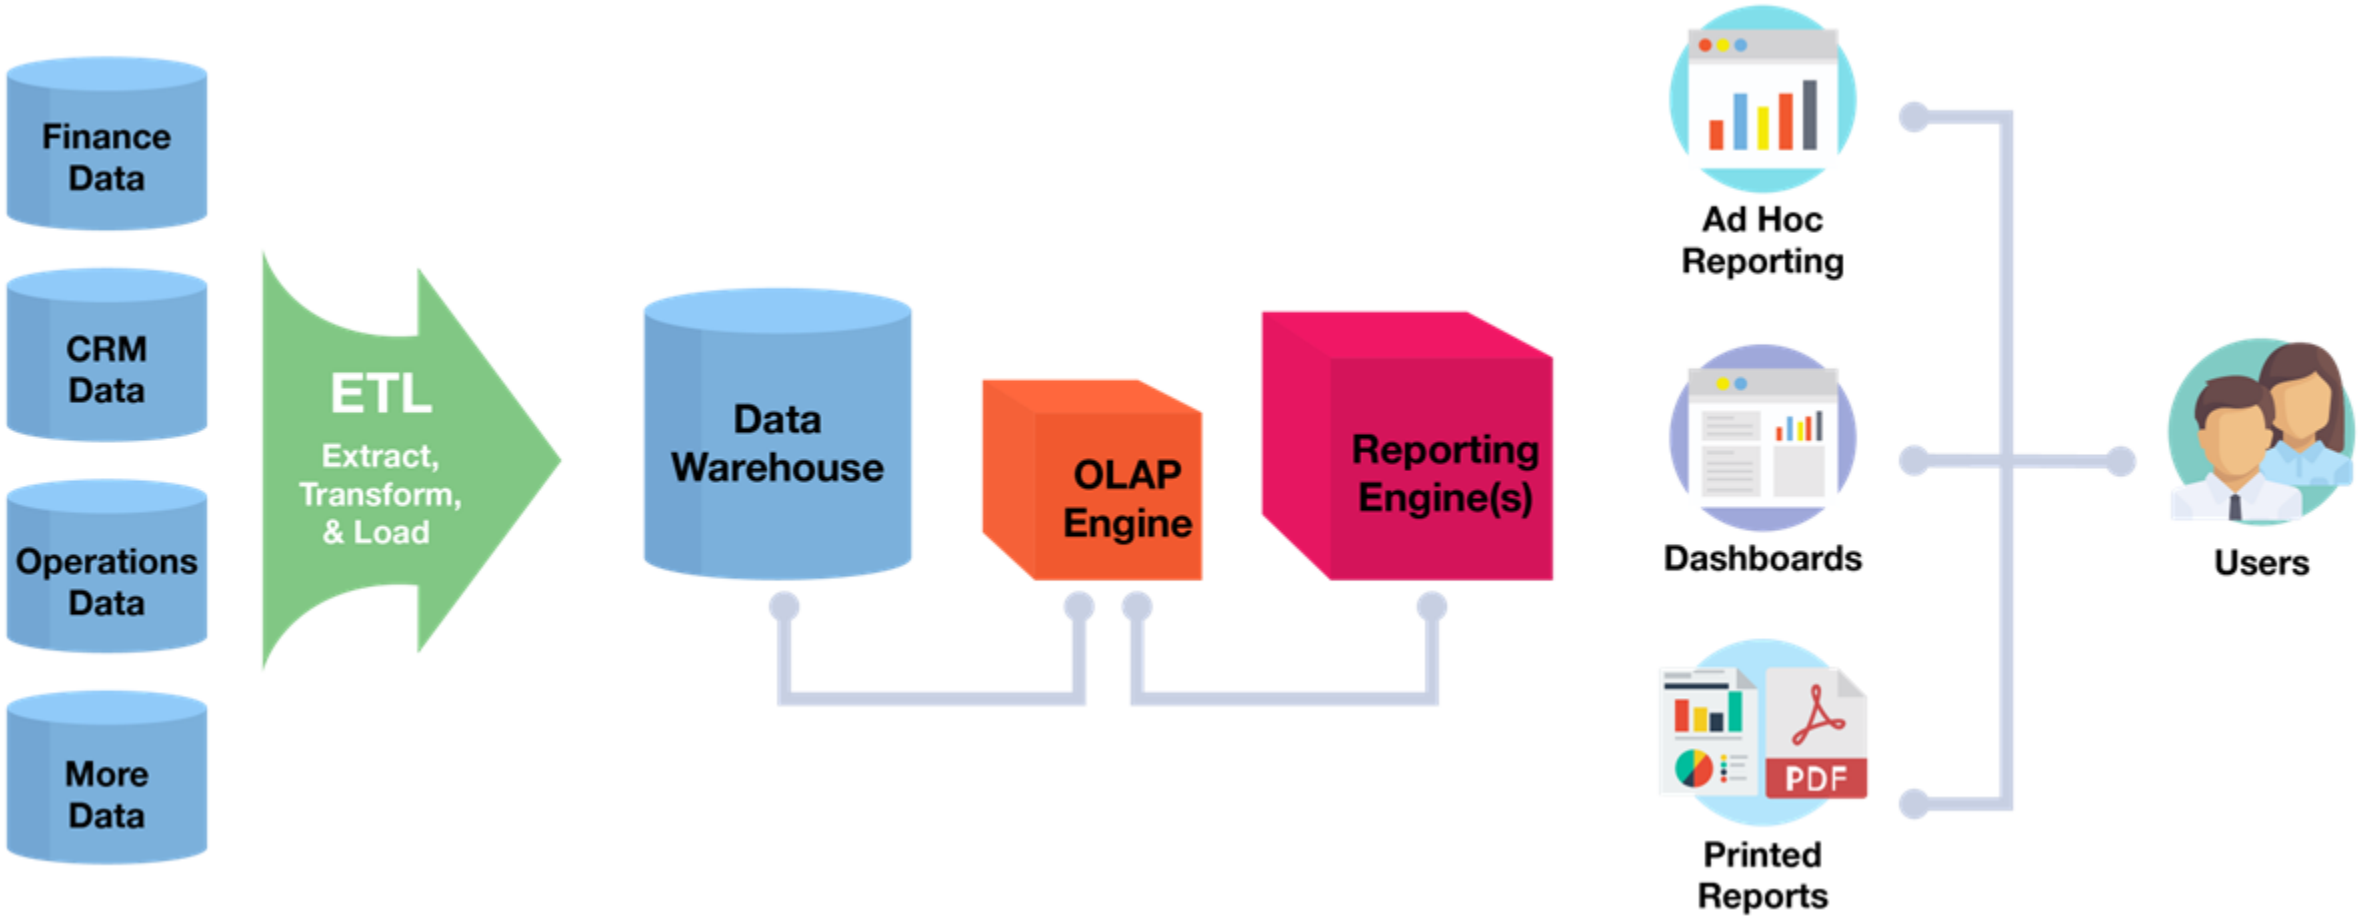

https://www.bigdataframework.org/analytics-business-intelligence-and-bi-whats-the-difference/

Inteligencia de Negocios con Big Data

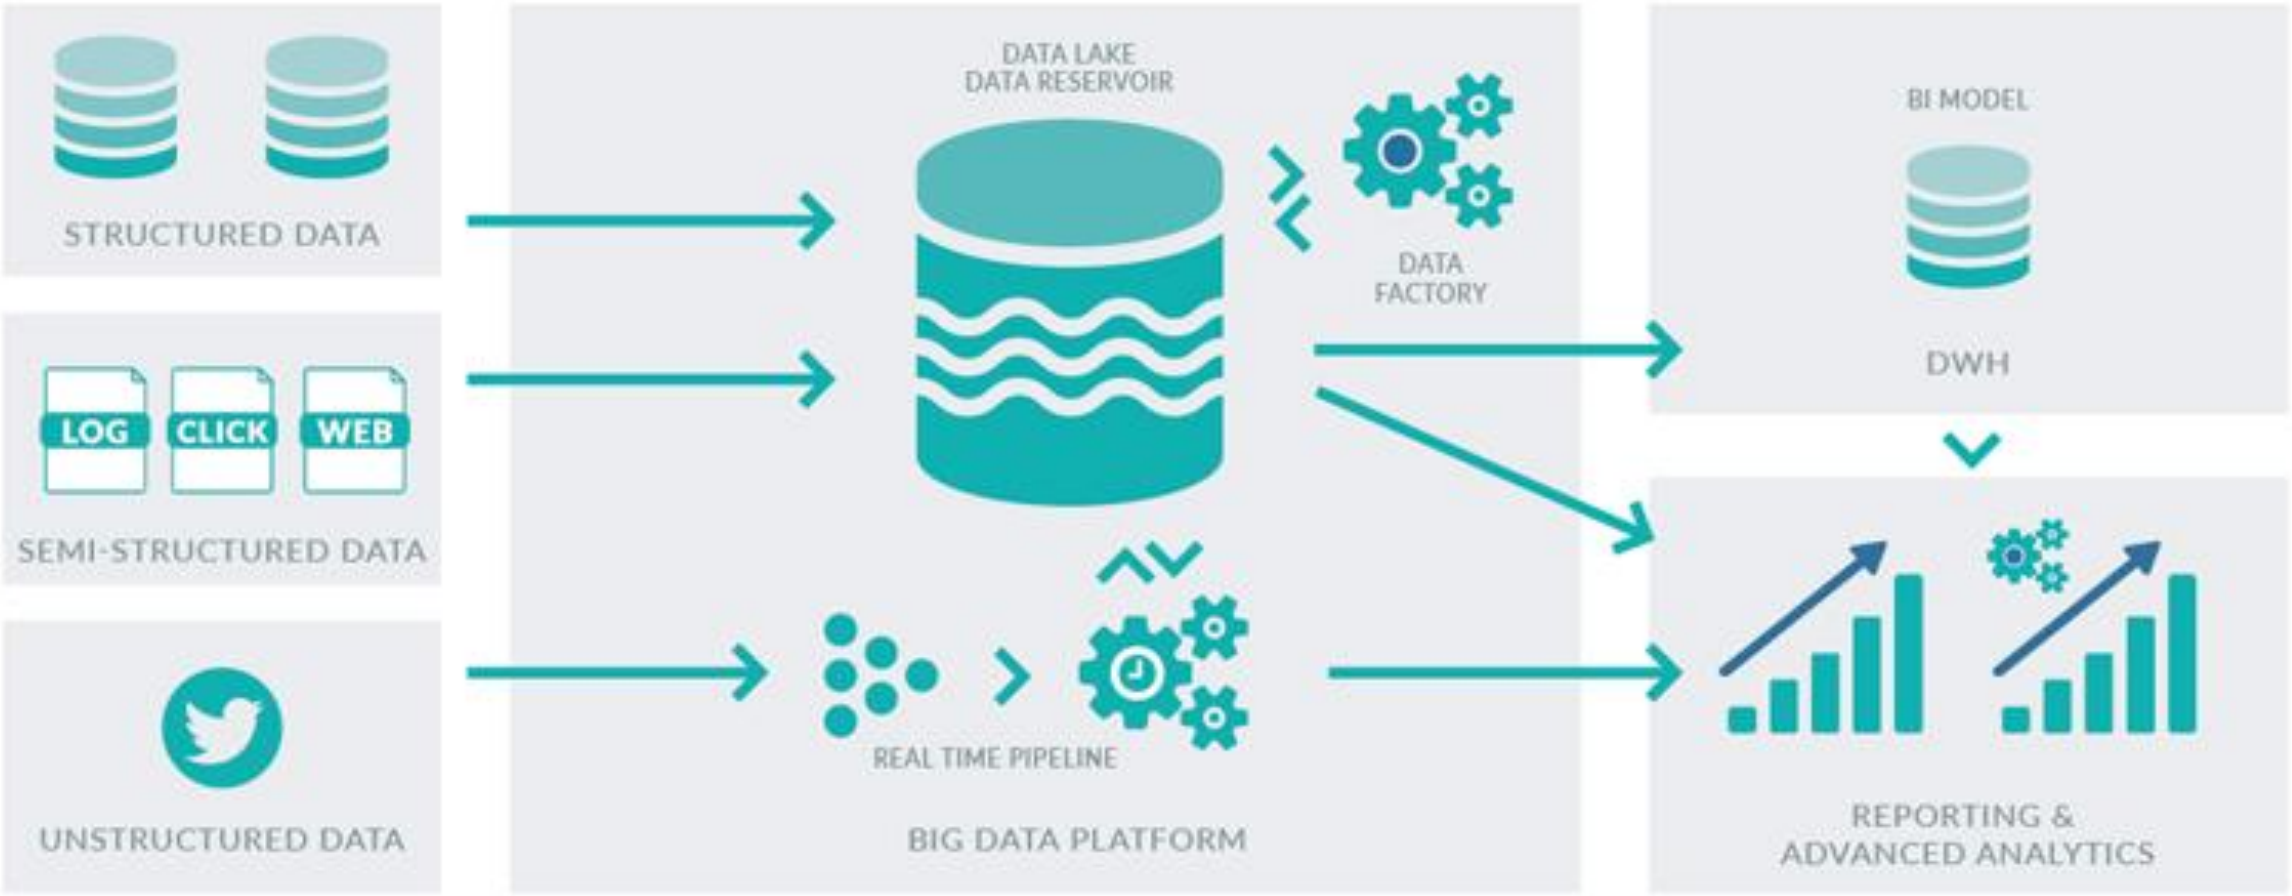

https://www.clearpeaks.com/what-can-big-data-do-for-bi/

AGENDA

UdeA
Analytics & DataScience

1. Contexto
2. **Procesamiento de Datos**
3. Cloud Computing
4. Aplicaciones

Fuentes y almacenamiento de datos

Antes de procesar datos**,** es fundamental comprender **de dónde provienen los datos** y **cómo se almacenan**.

Las decisiones sobre fuentes y almacenamiento impactan directamente en:

- La arquitectura de un sistema
- La latencia y el rendimiento
- Los costos
- La escalabilidad
- El tipo de análisis que se puede realizar

Las fuentes de datos pueden producir información:

- De forma **continua** (streaming),
- De forma **periódica o puntual** (batch).

Tipos de fuentes de Datos

- **Fuentes Operacionales:** Soportan la operación diaria de una organización
- **Generadas por aplicaciones:** Eventos generados continuamente pot la aplicaciones
- **IoT y Sensores**: Dispositivos físicos que generan mediciones periódicas
- **Logs y Telemetría:** Datos generados para monitoreo y diagnóstico
- **Fuentes externas:** Datos que provienen de terceros

Tipos de almacenamiento de datos

- **Almacenamiento Transaccional:** Optimizado para operaciones rápidas y consistentes

- **Almacenamiento de eventos:** Almacena los eventos en orden, tal como ocurren

- **Almacenamiento histórico (Data Lakes):** Almacenar datos en su formato original

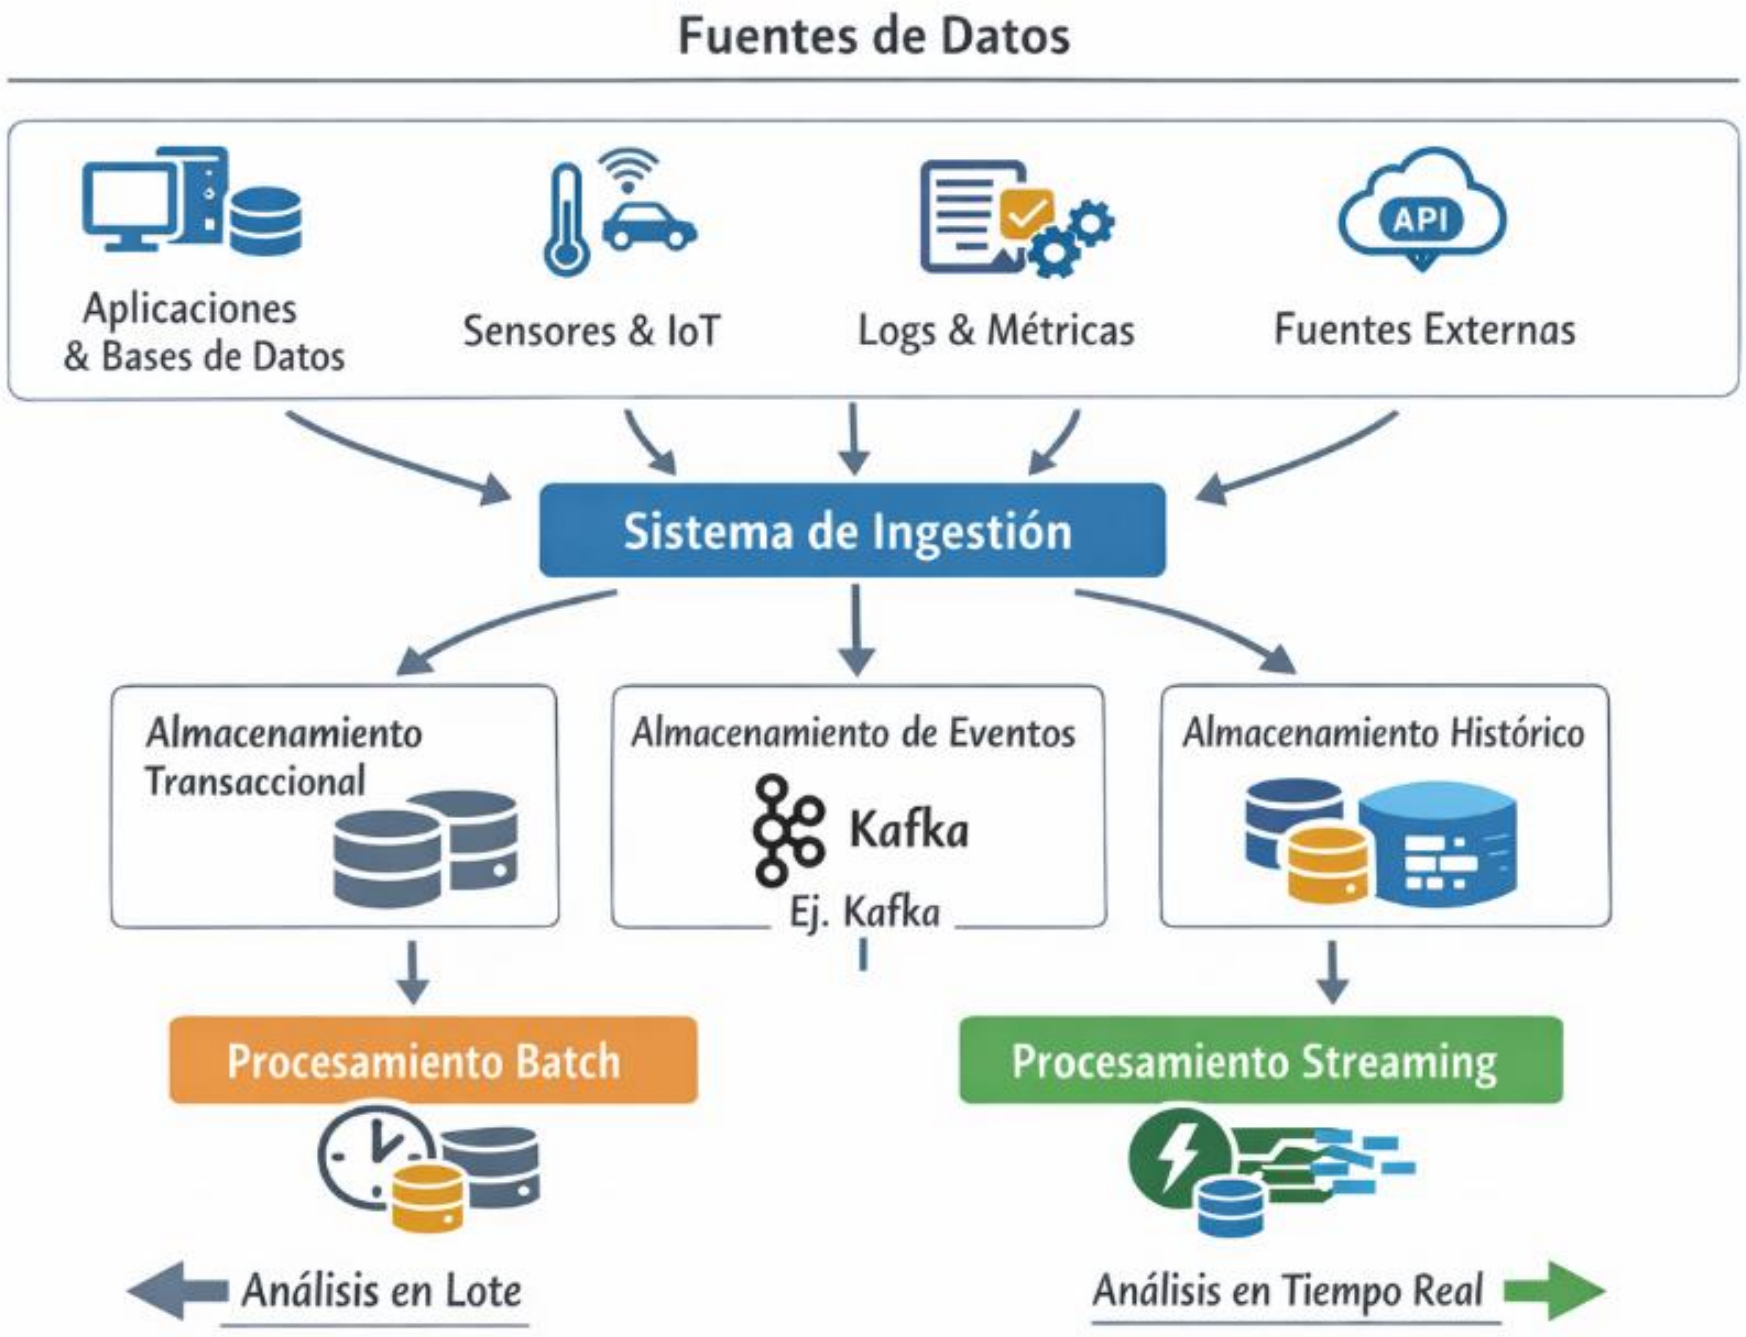
Fuentes de Datos
Aplicaciones & Bases de Datos
Sensores & IoT
Logs & Métricas
API
Fuentes Externas
Sistema de Ingestión
Almacenamiento Transaccional
Almacenamiento de Eventos
Kafka
Ej. Kafka
Almacenamiento Histórico
Procesamiento Batch
Procesamiento Streaming
Análisis en Lote
Análisis en Tiempo Real

Data Lake

Data Lake (Lago de datos) consiste en un repositorio centralizado donde es posible almacenar grandes cantidades de **datos estructurados y no estructurados**

Permite **almacenar los datos tal y como están, y procesarlos posteriormente bajo demanda**, es decir que no es necesario almacenarlos con una estructura de datos definida

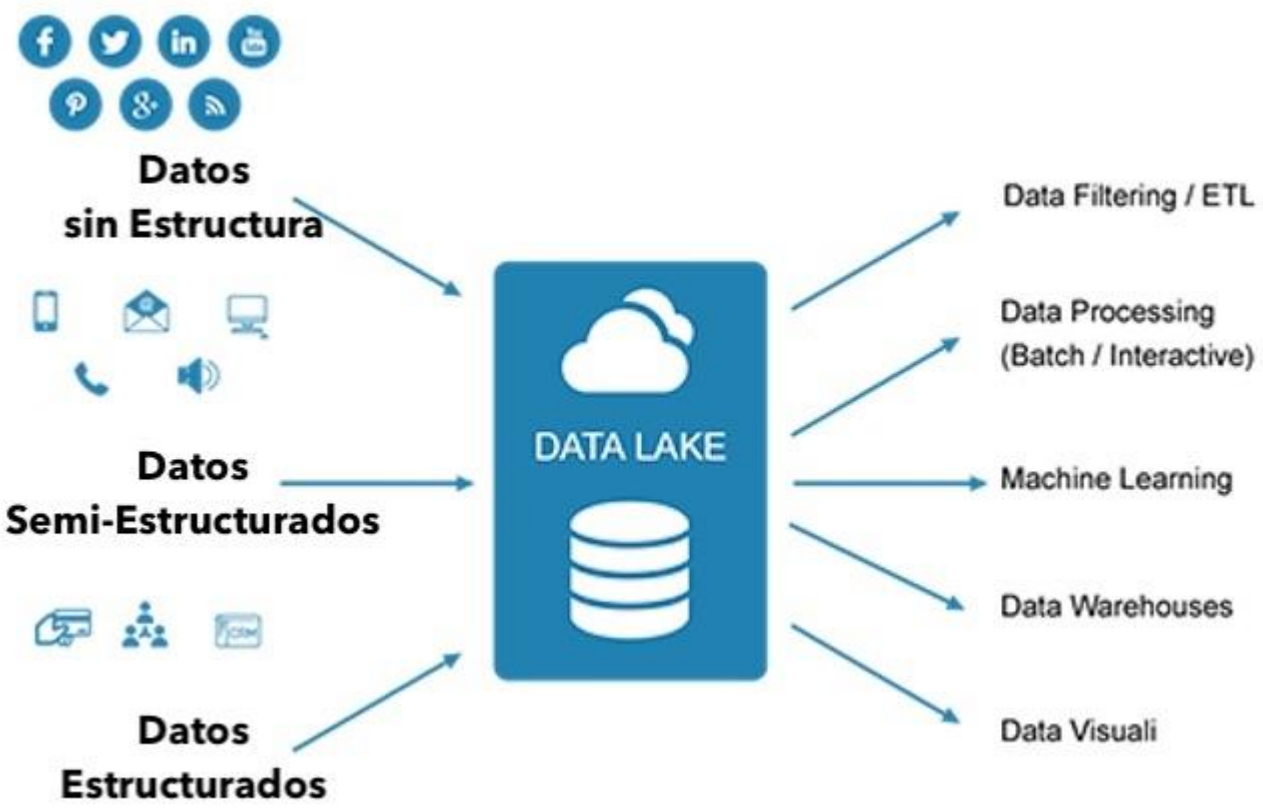

Data Warehouse

Un **Data Warehouse** es un repositorio central diseñado para **consultas analíticas** (reportes, BI, dashboards, métricas) con datos típicamente:

- **Estructurados** (tablas bien definidas)
- **Limpios y transformados**
- Con **gobernanza y control de calidad**
- Optimizados para consultas SQL (agregaciones, joins, filtros)

Piensa en el Data Warehouse como la versión oficial y confiable de los datos para análisis del negocio.

Data Lake vs Data Warehouse

Aspecto	Data Lake	Data Warehouse
Tipo de datos	Cualquier formato	Principalmente estructurado
Enfoque	Almacenar primero, modelar después	Modelar y limpiar antes de cargar
Esquema	Schema-on-read	Schema-on-write
Uso típico	ML, históricos, auditoría, exploración	BI, KPIs, reporting, analítica gobernada
Costos	Muy eficiente para almacenar	Optimizado para consulta (puede costar más por rendimiento)
Herramientas típicas	AWS S3 Azure Data Lake Storage (ADLS Gen2) Google Cloud Storage (GCS)	Amazon Redshift Google BigQuery Azure Synapse Analytics

Data Lake no reemplaza al Warehouse, se complementan.

Tipos de procesamiento

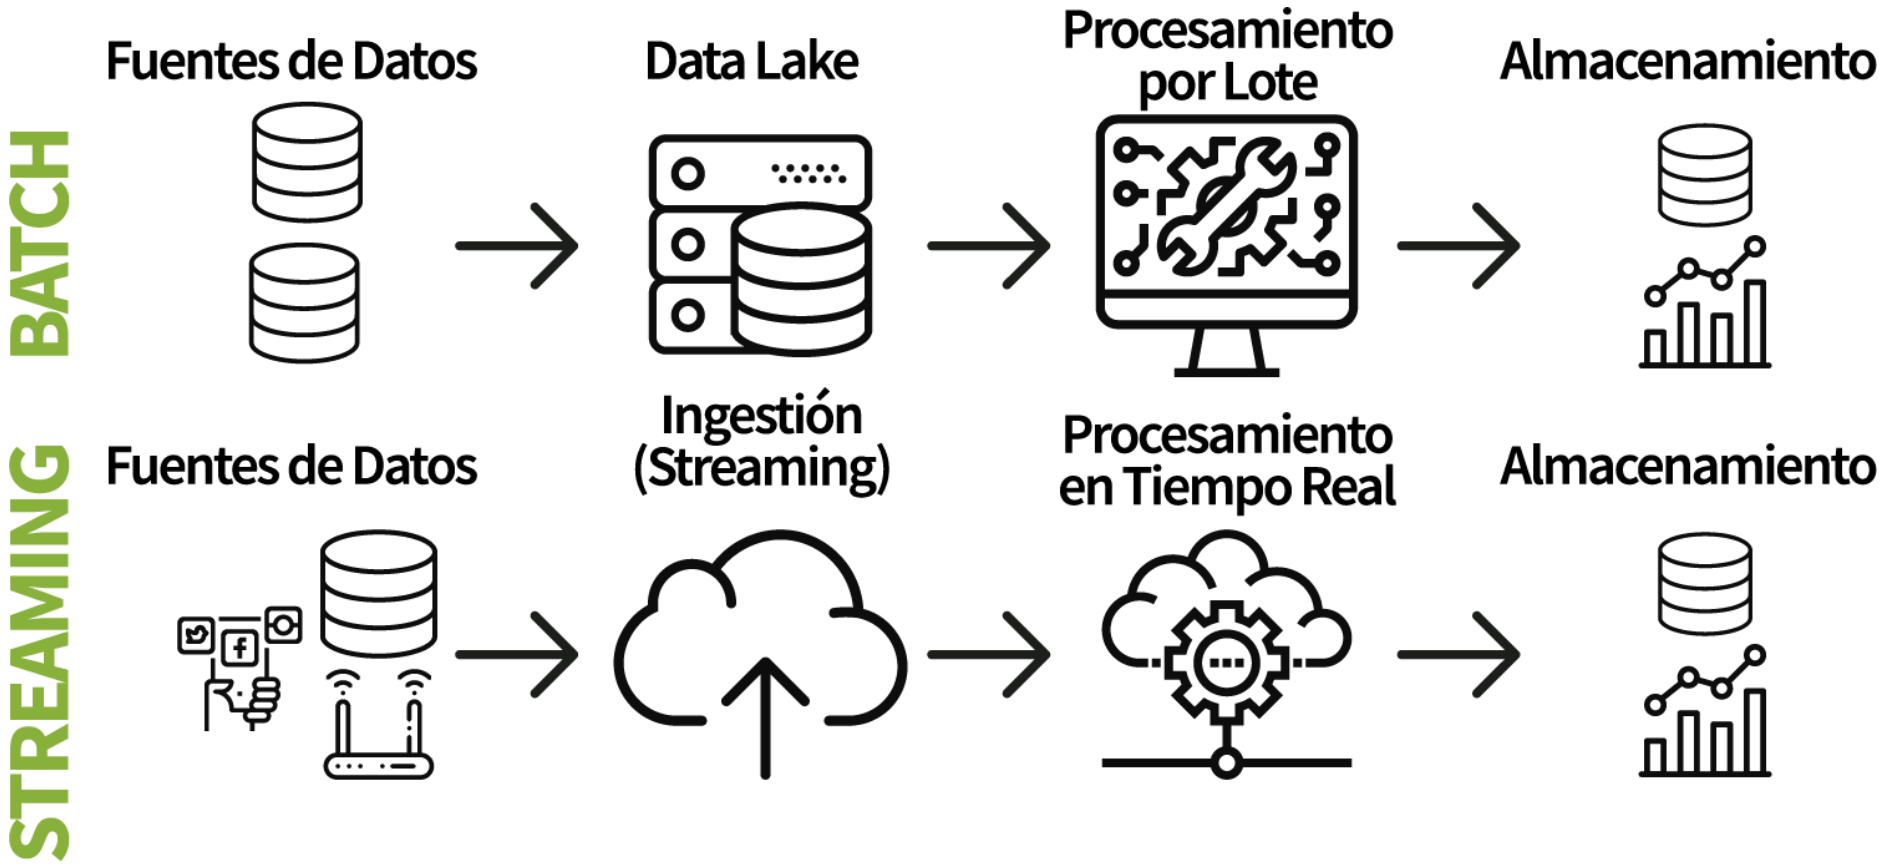

https://www.pandaid.com/big-data-procesos-en-tiempo-real/

Procesamiento en Batch

- Un lote (batch) es una colección de datos que ha sido agrupada durante un **intervalo de tiempo**
- Realiza periódicamente trabajos repetitivos de grandes volúmenes de datos (**millones de registros**)
- Requiere un **gran esfuerzo computacional**
- Se suelen ejecutar en **horas de menor actividad**
- Las tareas se pueden ejecutar de forma secuencial o **simultánea**

Procesamiento en Batch

- Requieren una **interacción humana mínima** ejecutando de manera eficiente tareas repetitivas

- Se recomienda utilizarlos en **proceso que tomen mucho tiempo en ser realizados** sea por el gran volumen de los datos o por la complejidad misma del proceso

https://reysantech.com/blog/como-se-procesa-la-informacion-en-big-data/

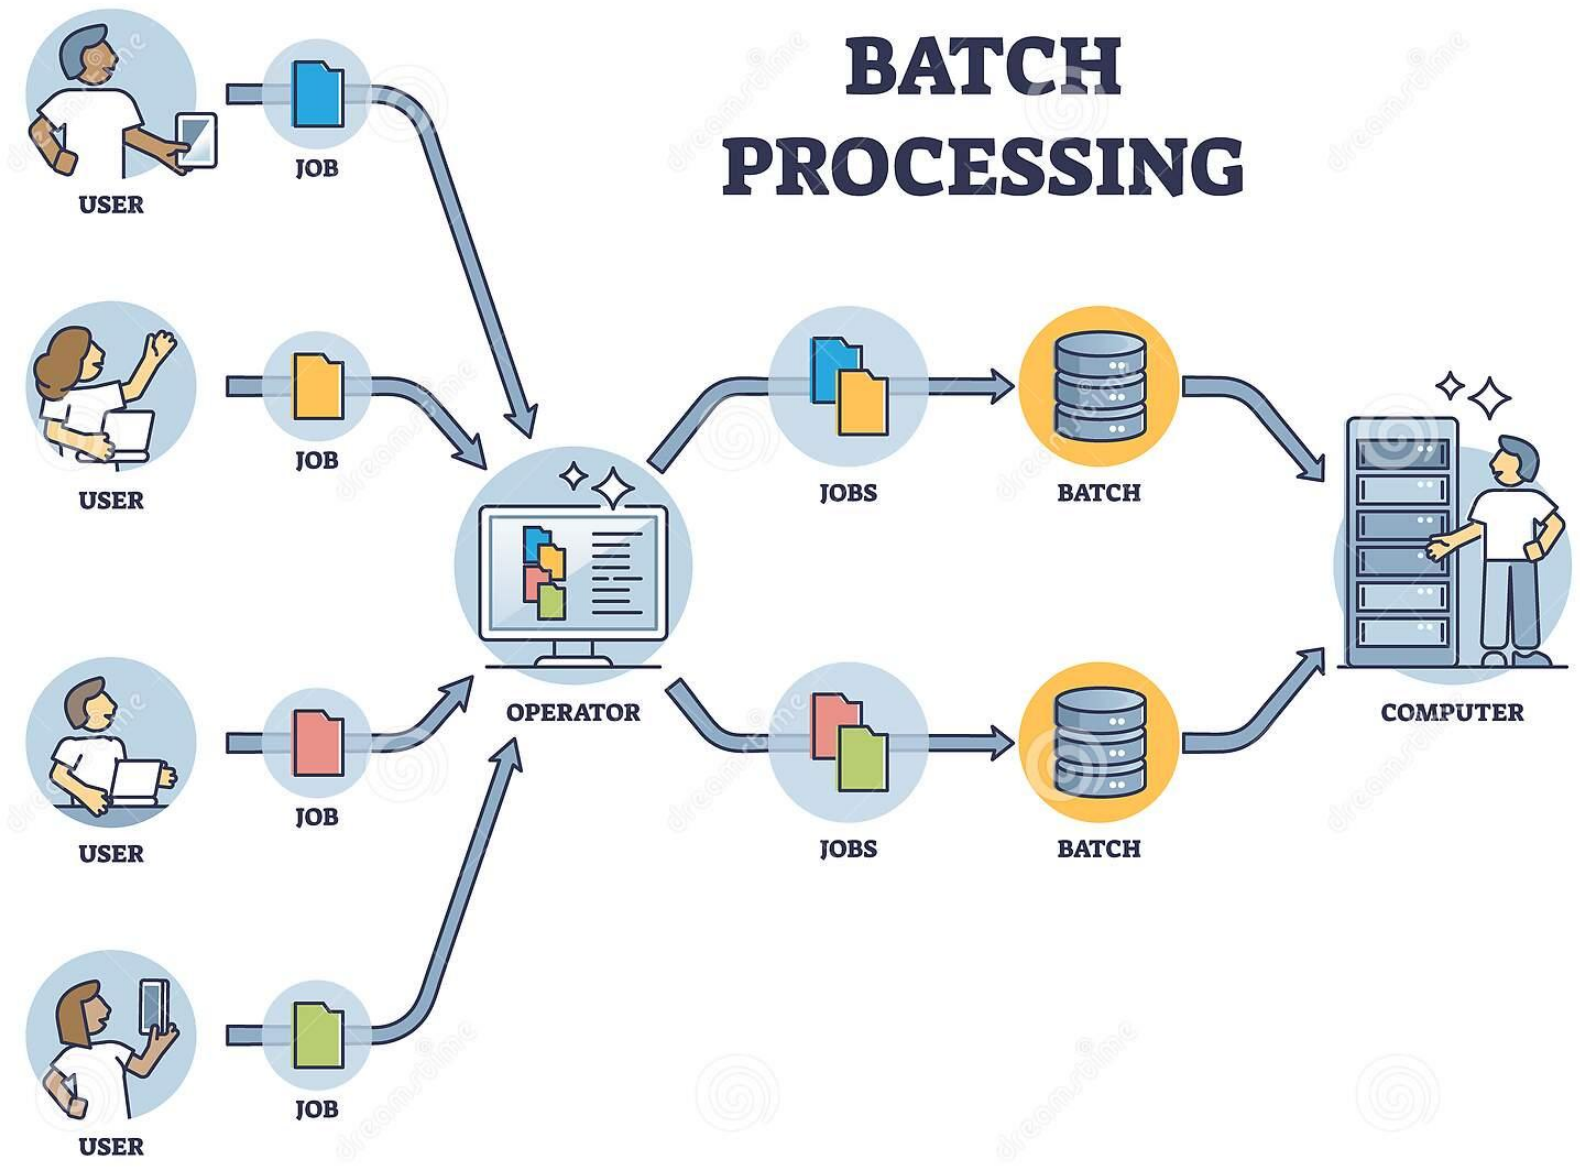

dreamstime.com
ID 243001929 © VectorMine

Procesamiento en Batch

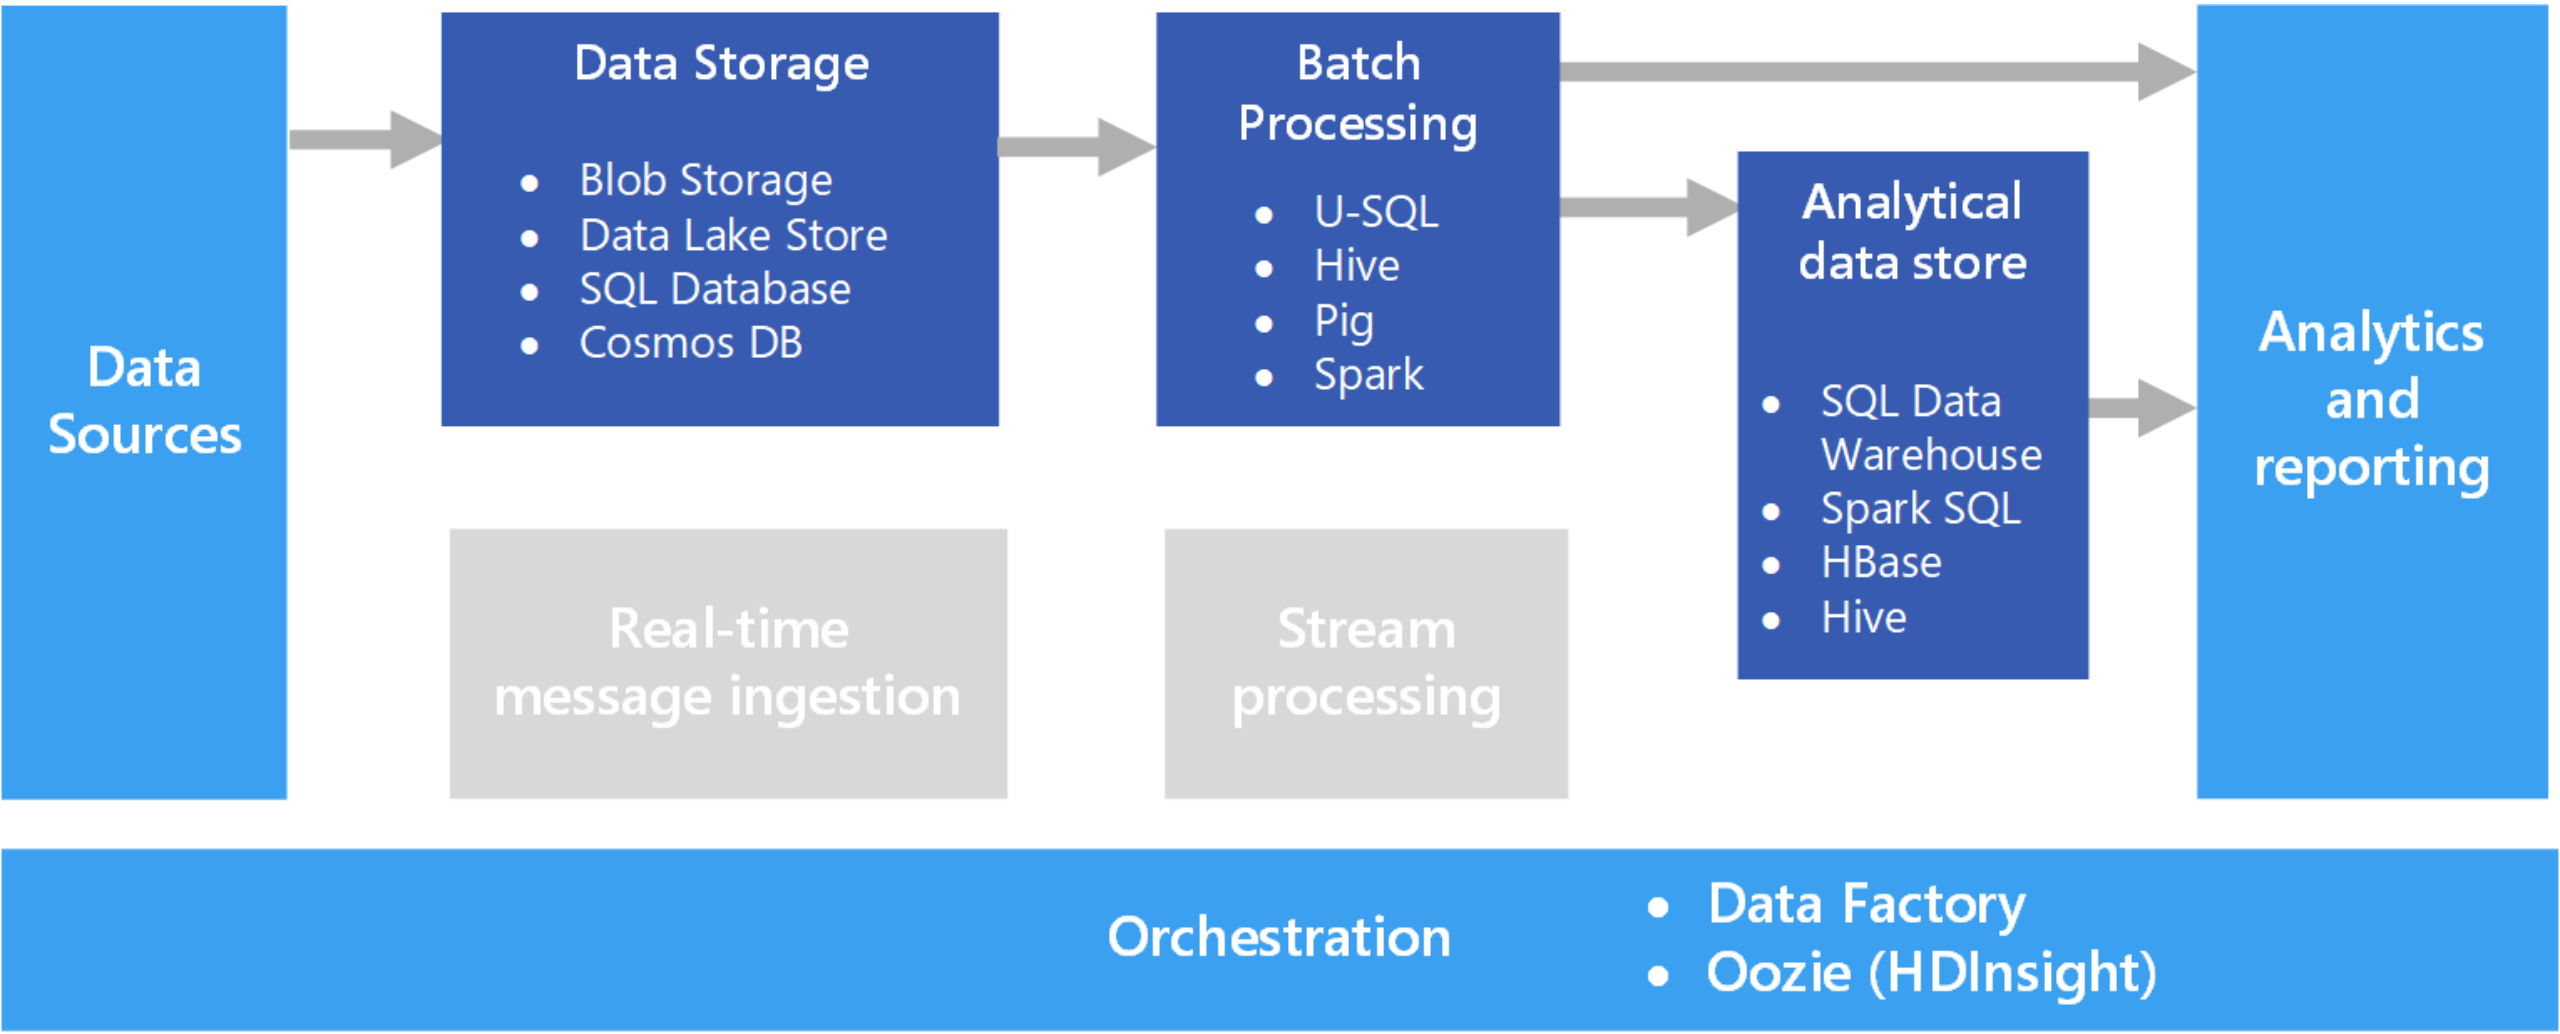

https://learn.microsoft.com/es-es/azure/architecture/data-guide/big-data/batch-processing

Procesamiento en Batch - Ejemplos

- Gestión de Inventario
- Informes Automatizados
- Facturación como un proceso periódico (semanal o mensual)
- Actualización de modelos de Machine Learning

Procesamiento en Batch - Ejemplos

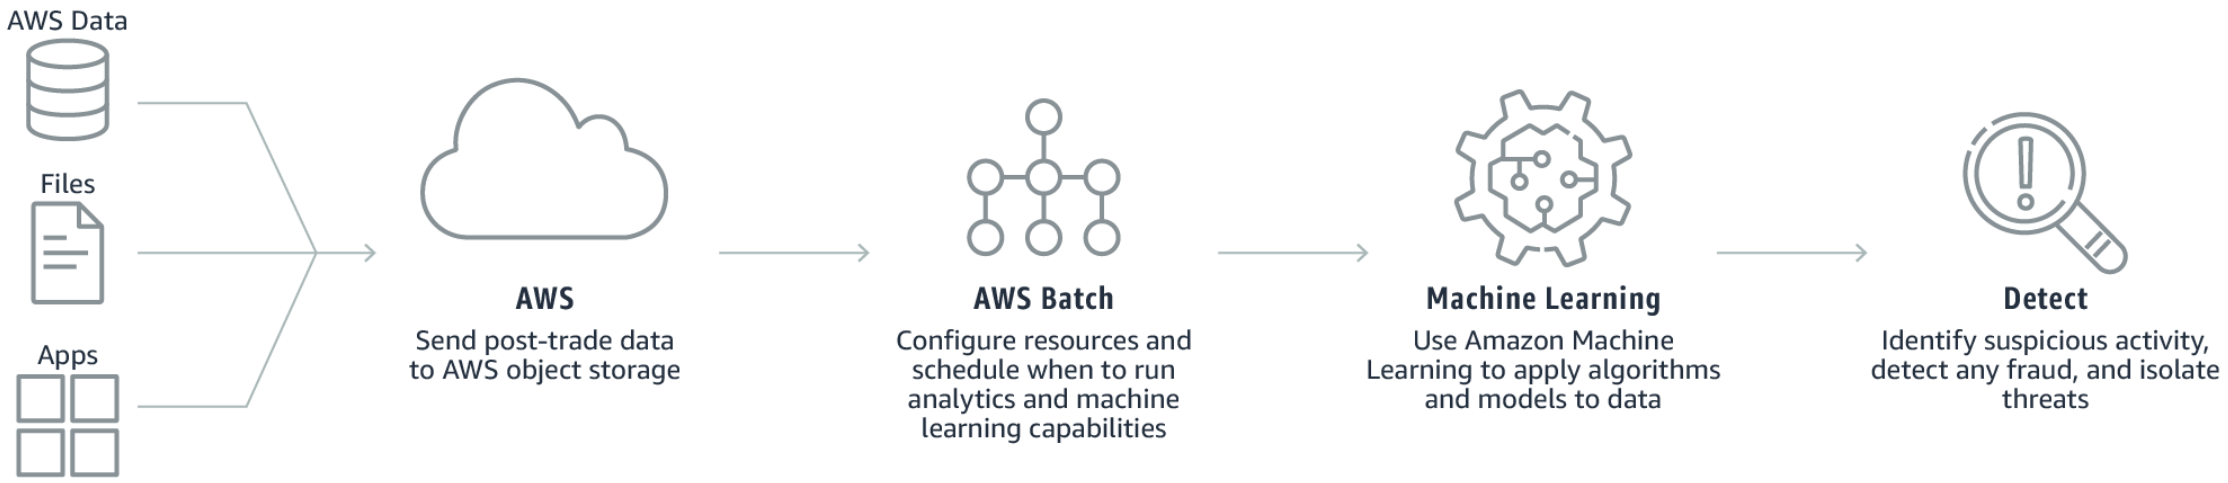

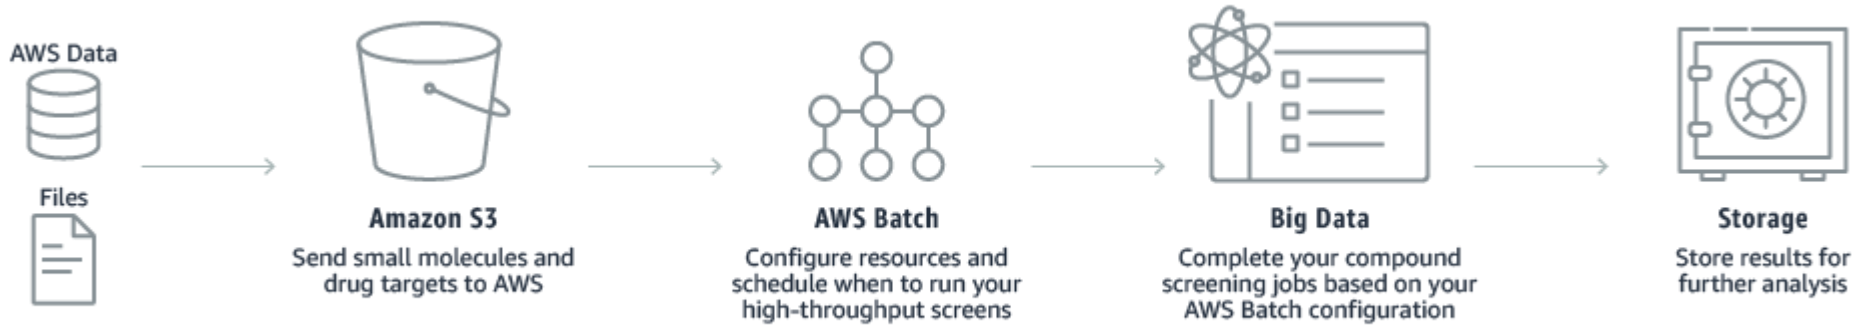

https://aws.amazon.com/es/batch/use-cases/

Procesamiento en Streaming

- Los datos se generan y transmiten en tiempo real en **pequeños paquetes (kb)**
- Al recibir los datos, se debe procesar registro por registro de **forma secuencial**
- Se requiere una latencia muy baja del orden de segundos o incluso **milisegundos**
- Se requiere de una capa de **almacenamiento** y otra de **procesamiento**

Procesamiento en Streaming

- Permite **procesar los datos de forma continua en el mismo instante en que llegan** sin esperar ningún otro evento

- Cada lectura de datos se concibe como un **flujo de datos** que pueden representarse como un conjunto de lista de valores o como un conjunto de pares clave-valor

https://reysantech.com/blog/como-se-procesa-la-informacion-en-big-data/

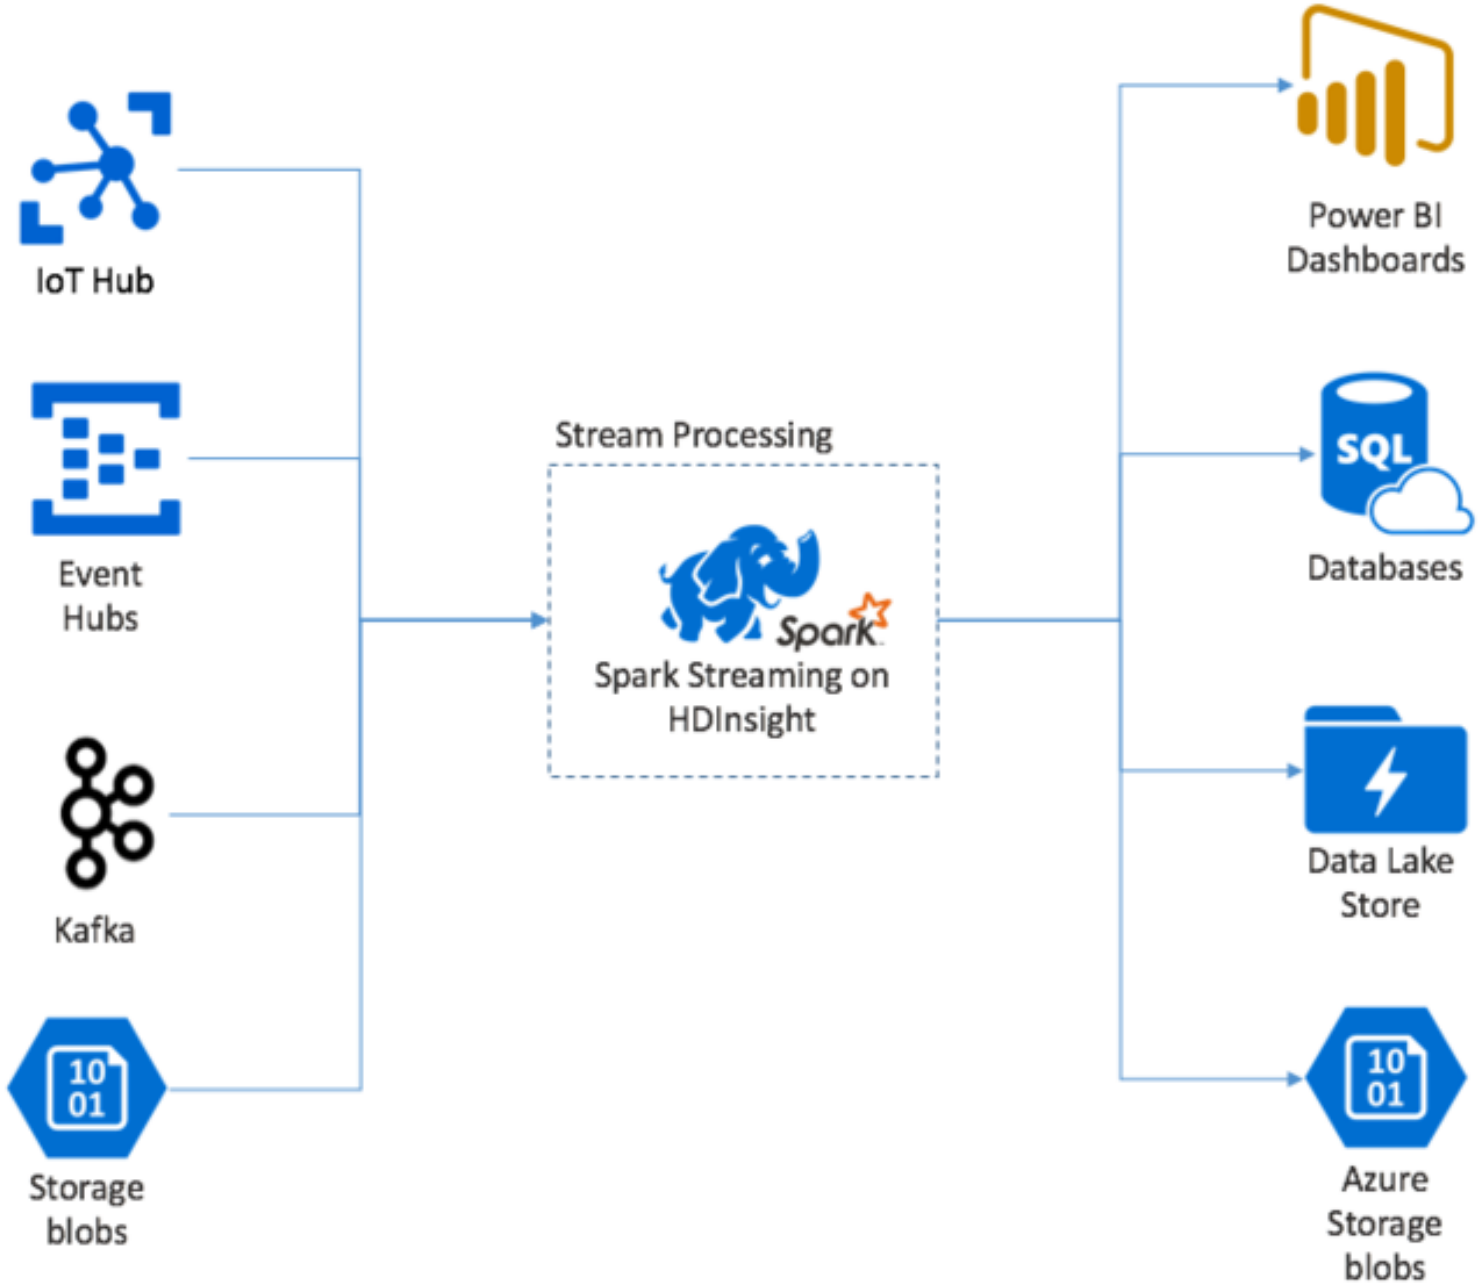

El procesamiento de datos en Streaming usualmente es realizado en **cluster de Spark** que garantizan que cada uno de los eventos sea procesado de manera correcta incluyendo el concepto de la tolerancia a fallas

https://learn.microsoft.com/es-es/azure/hdinsight/spark/apache-spark-streaming-overview

Data Stream

- Data Stream o flujo de datos se refiere a la transmisión de una secuencia de señales codificada digitalmente en paquetes para transmitir información

- Data Stream tiene la necesidad de **procesar y realizar análisis en tiempo real**

- En el Data Stream cuenta con una naturaleza continua de generación de datos a gran velocidad, que implica que los datos sean procesados sin necesidad de ser previamente almacenados

Procesamiento en Streaming - Ejemplos

- En **videojuegos**, la interacción del jugador se puede transmitir para ser analizada en tiempo real y **ofrecer experiencias dinámicas**

- Una **página web** puede almacenar los **registros de clics** de cada usuario para aprender sobre su comportamiento y **ofrecer contenido adecuado**

- Los comentarios en **redes sociales** se pueden analizar para **gestionar** las **publicaciones** de una marca de manera oportuna

Procesamiento en Streaming - Ejemplos

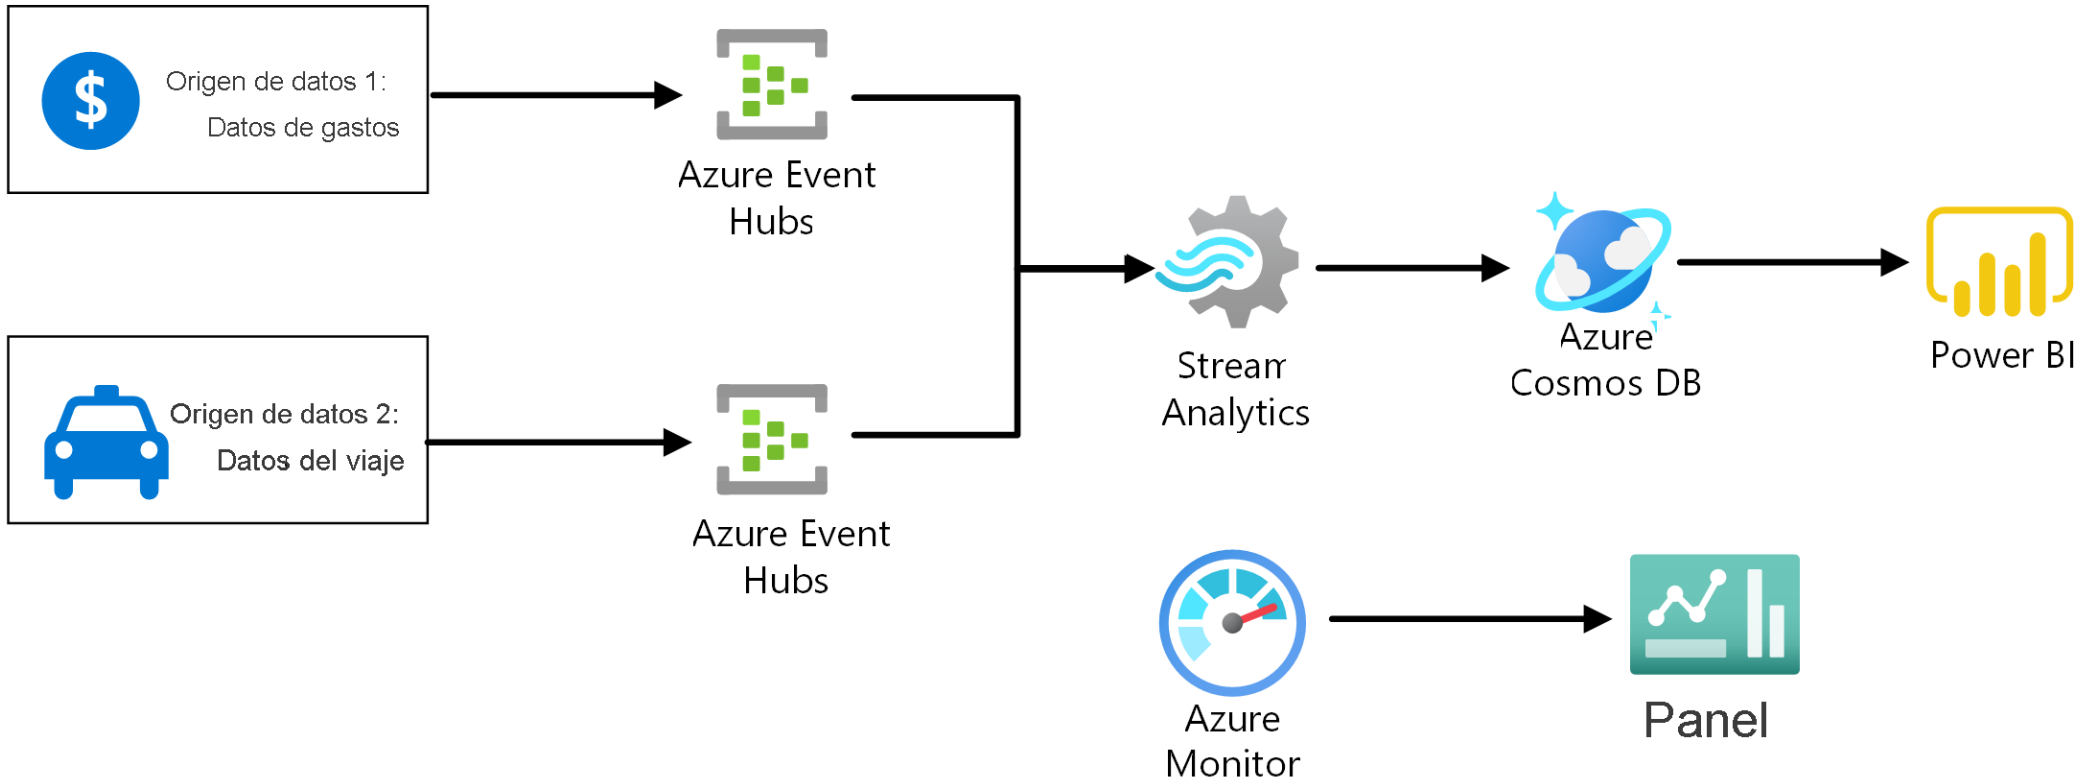

Microsoft Azure

https://learn.microsoft.com/es-es/azure/architecture/reference-architectures/data/stream-processing-stream-analytics

Procesamiento en micro-batch

- El procesamiento en micro lotes consiste en **agrupar los datos en pequeños grupos o lotes** para luego ser procesados en conjunto.

- Es una variante del procesamiento por lotes, donde **se procesan grupos pequeños de nuevos datos** y se debe determinar una frecuencia de procesamiento de datos.

- A pesar de no ser un verdadero procesamiento en tiempo real, es suficiente para un gran número de aplicaciones

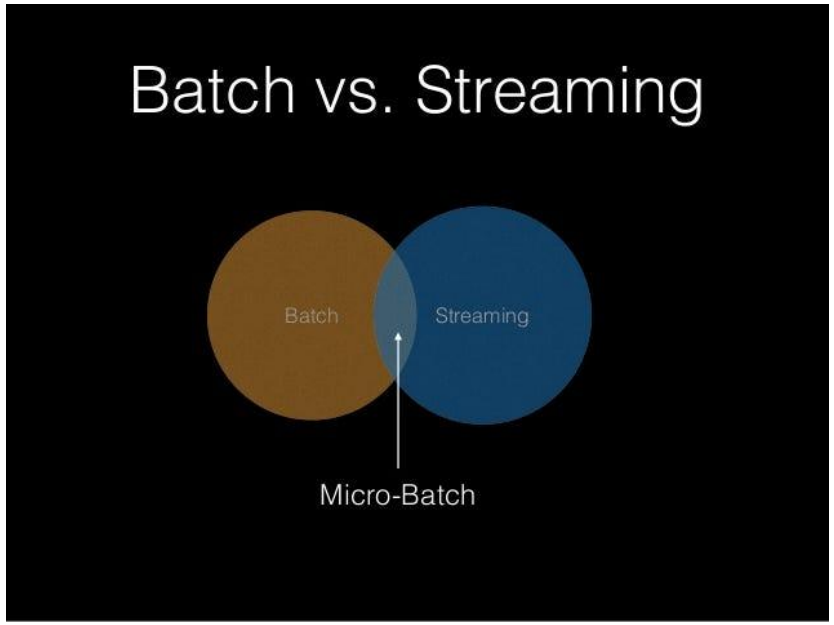

Procesamiento en micro-batch

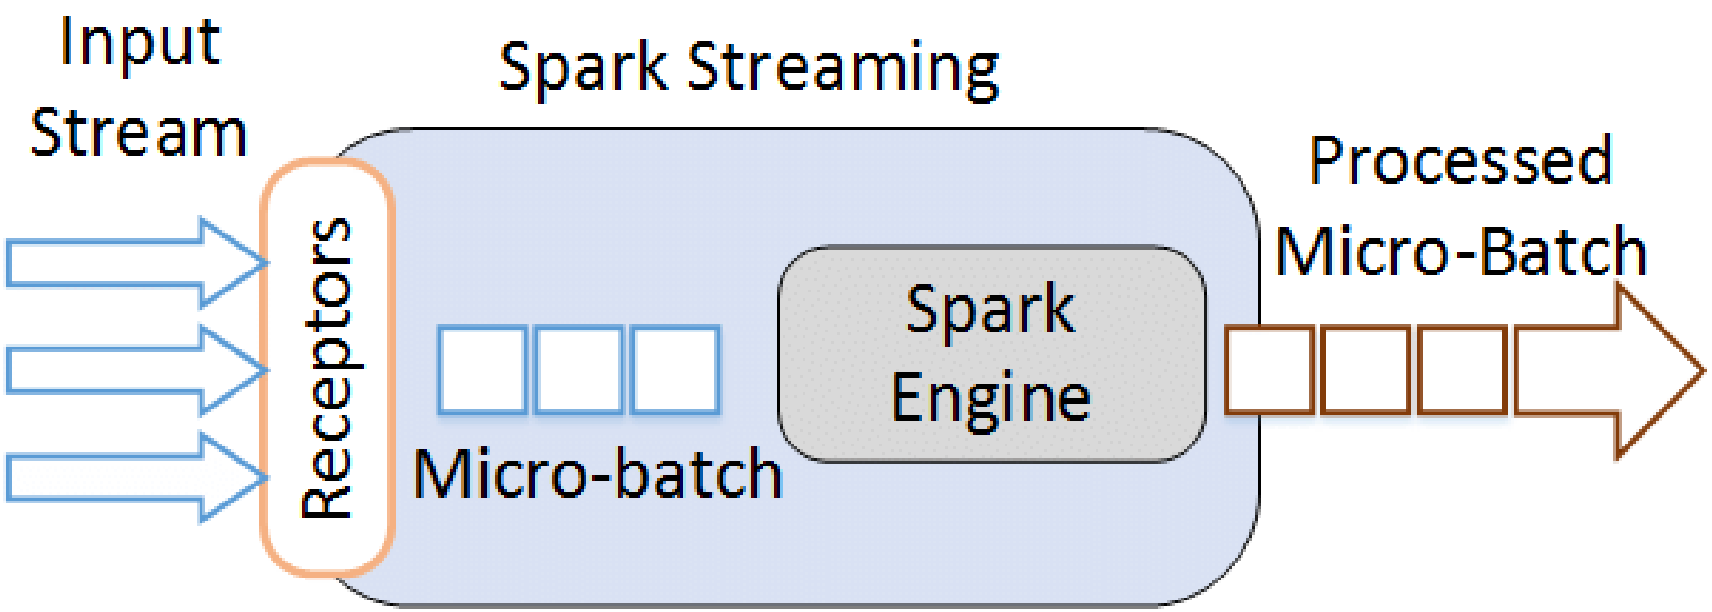

https://www.researchgate.net/figure/Micro-batch-processing-used-in-Spark-stream-The-input-streams-are-received-by_fig6_327183263

micro-batch vs Native Stream

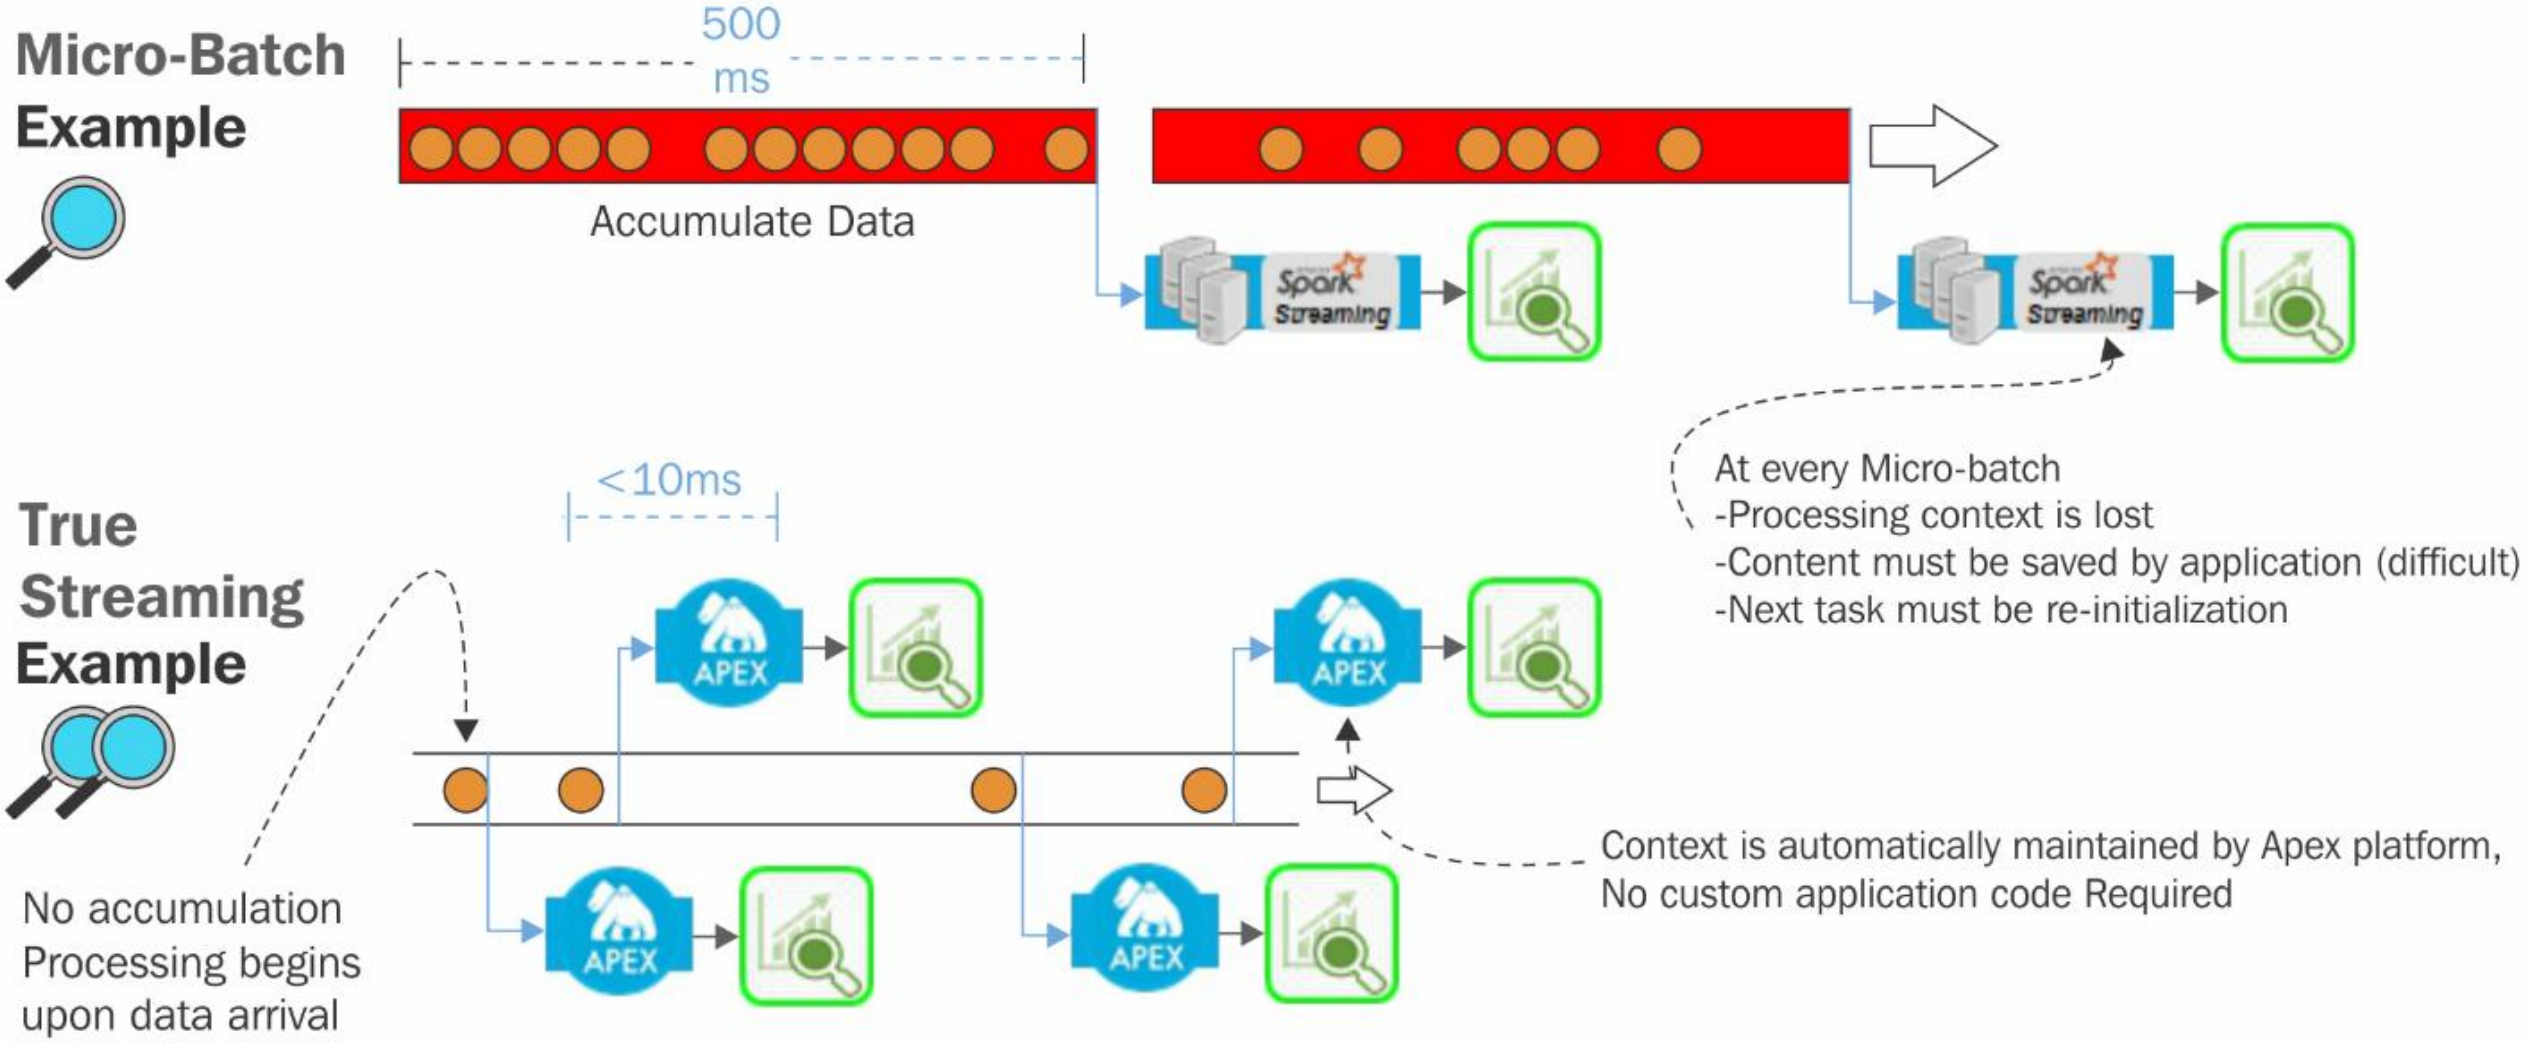

https://www.oreilly.com/library/view/learning-apache-apex/9781788296403/03a5ebbf-2a16-4a24-ab20-10175358ab7b.xhtml

AGENDA

UdeA
Analytics & DataScience

1. Contexto
2. Procesamiento de Datos
3. **Cloud Computing**
4. Aplicaciones

Definición Cloud Computing

Plataforma **altamente escalable** que promete un acceso rápido al recurso **hardware** o **software** y donde el usuario **no necesita ser experto** para su manejo y acceso.

http://www.innovacion.gob.pa/descargas/FAQ_CloudComputing.pdf

Modelo para habilitar el **acceso** a un conjunto de **servicios computacionales** de manera conveniente y **por demanda**, que pueden ser rápidamente aprovisionados y liberados con un esfuerzo administrativo y una interacción con el proveedor del servicio mínimos.

https://nvlpubs.nist.gov/nistpubs/Legacy/SP/nistspecialpublication800-145.pdf

El navegador que antes solo servía para navegar en Internet, se está convirtiendo en nuestro sistema operativo

Tipos de Nube

- **Pública:** Vende sus servicios a **cualquier usuario**
- **Privada:** Se ofrecen los servicios a un número limitado de **usuarios previamente seleccionados**
- **Híbrida:** Combinación entre nube pública y privada

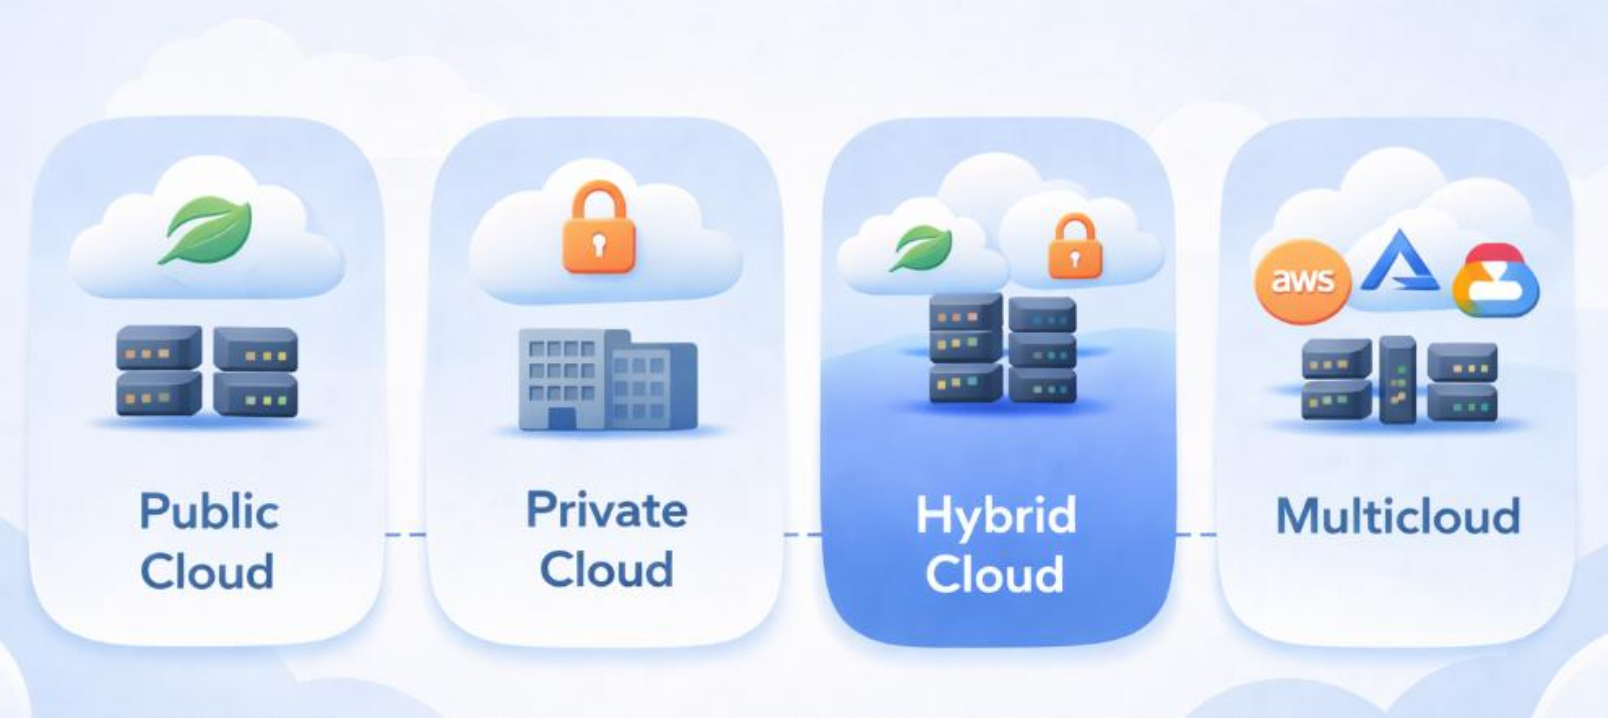

Características

- **Auto-servicio por demanda (On-demand self-service)** Disponer de las capacidades de computo, de acuerdo a la necesidad sin la intervención del proveedor del servicio

- **Acceso ubicuo a la red (Broad network access.)** Servicios disponibles para todo tipo de clientes y dispositivos simultáneamente

- **Rápida elasticidad (Rapid elasticity)** Recursos dinámicos, escalables y elásticos. Pueden variar en función de las necesidades

- **Medición del Servicio (Measured Service)** El uso de los recursos es monitoreado, medido e informado al usuario

Ventajas

Reducción de costos

No hay inversión en Hardware, mantenimiento y licencias. Se paga solo por los recursos utilizados

Optimización de recursos

Recursos dinámicos que están disponibles solo cuando son necesarios

Fácil recuperación

Los recursos están en la nube generalmente en distintas ubicaciones

Administración

El proveedor se puede encargar de tareas de mantenimiento, actualización, seguridad, ente otras

Disponibilidad

Acceso a los recursos desde cualquier lugar

“Desventajas”

Percepción de inseguridad

La información se encuentra por fuera de la empresa

Pérdida de control

No tenemos acceso físico al sitio donde están ubicados los recursos

Acceso a Internet

Si no tenemos Internet, no podemos usar nuestros recursos

Modelos de Servicio en la Nube

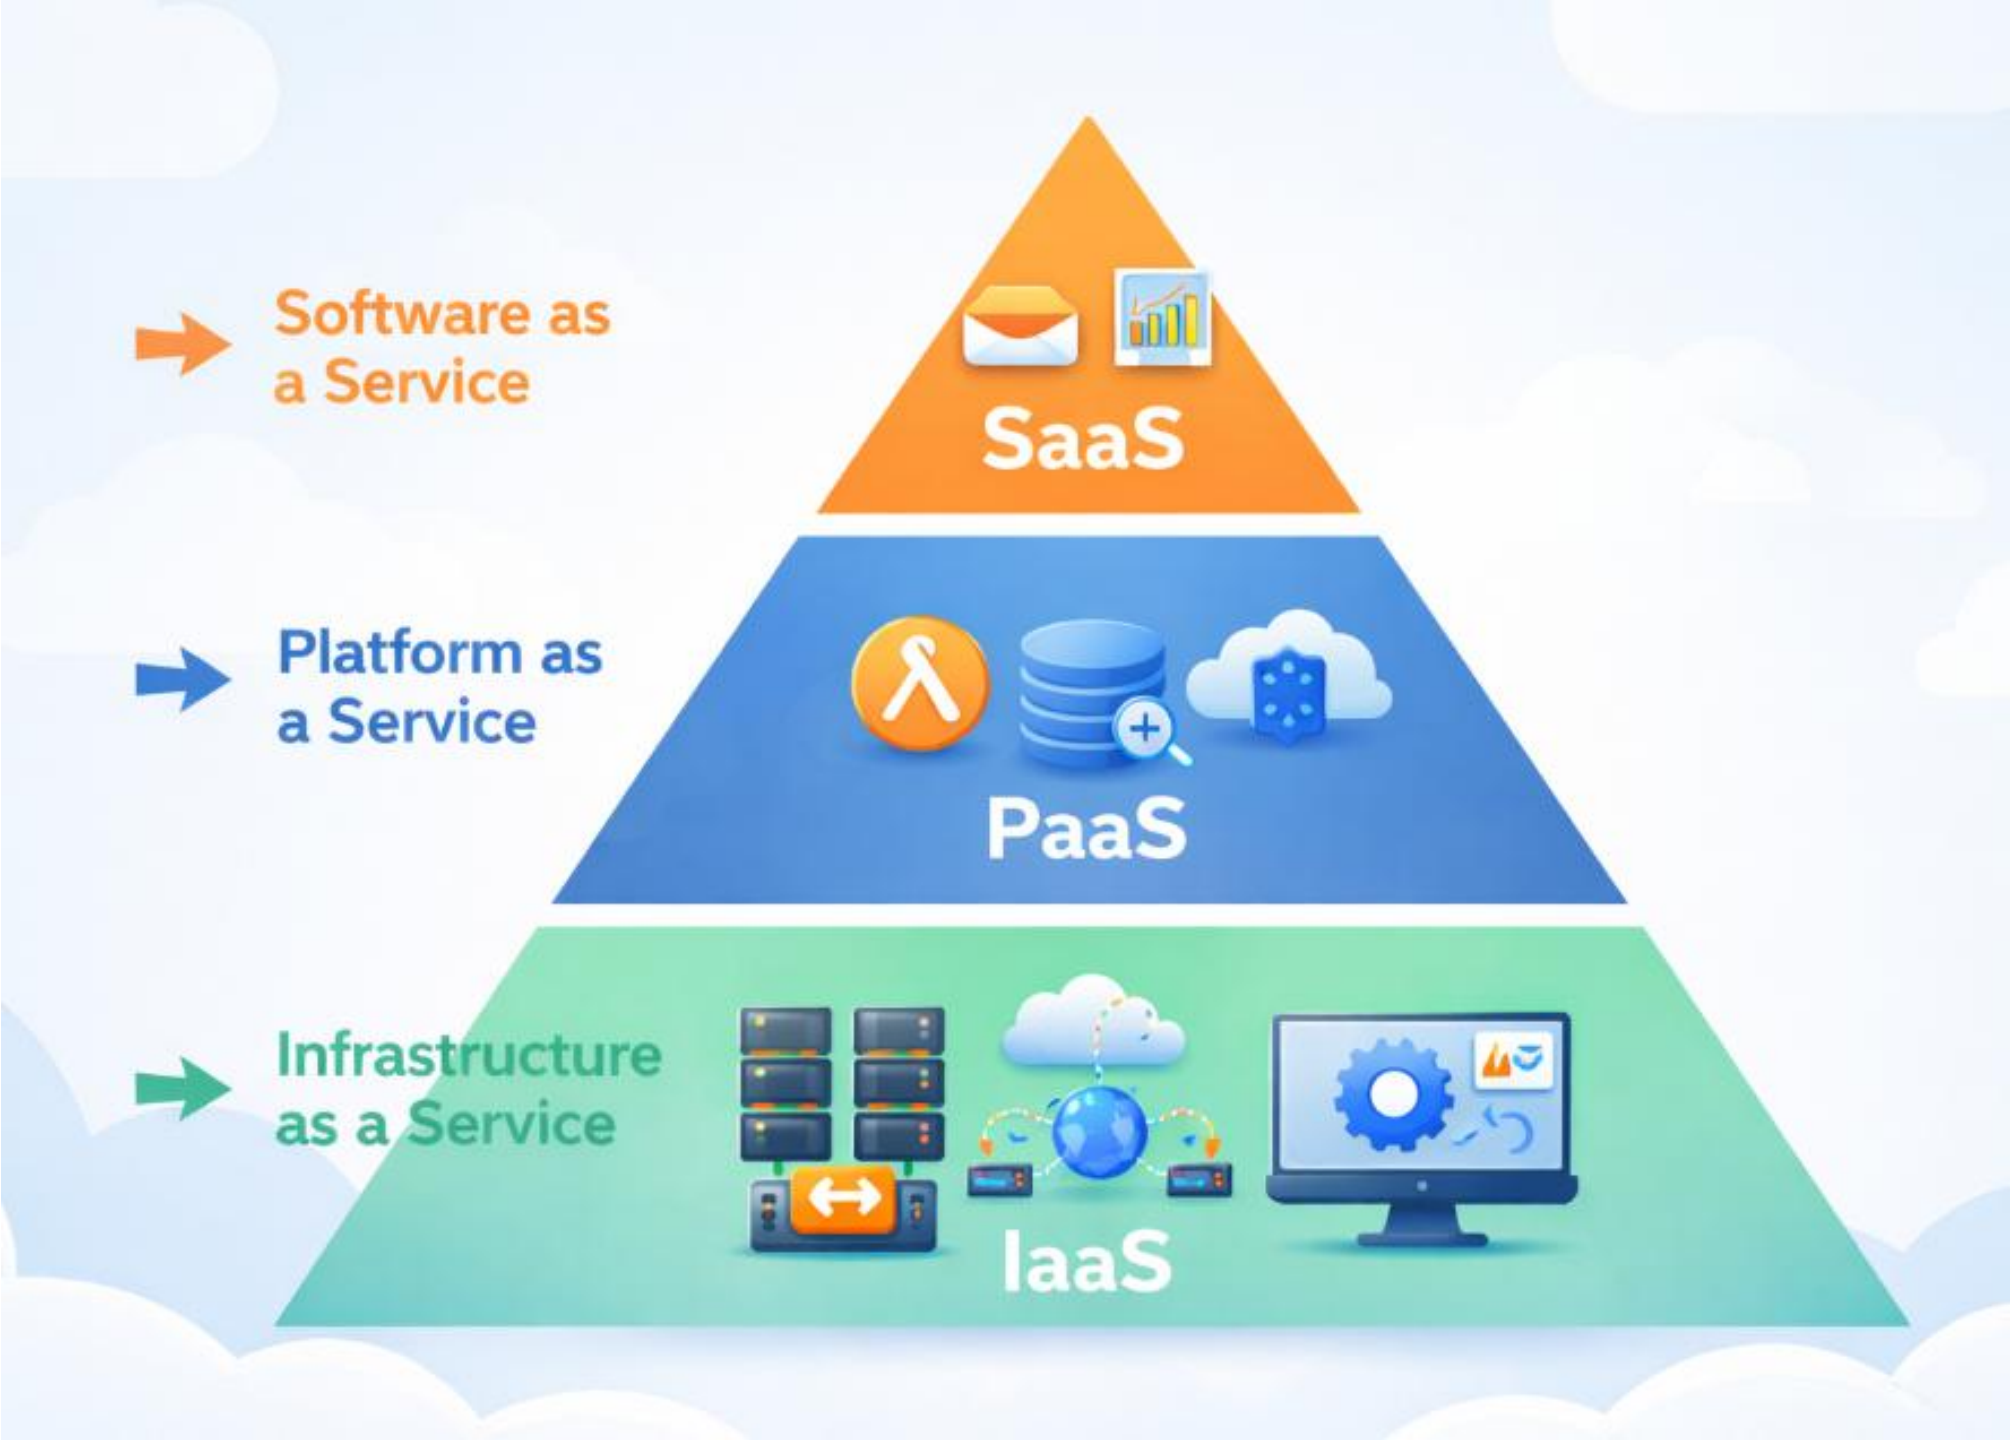

Software como servicio (SaaS, Software As A Service)

- El usuario accede al software que está alojado en infraestructura de nube
- La forma de acceder al Software es através de un navegador
- No hay control de la infraestructura

Plataforma como servicio (PaaS, Platform As A Service)

- Solución para la construcción y puesta en marcha de aplicaciones y servicios Web que estarán completamente disponibles a través de Internet.
- Se utiliza la infraestructura de nube para que el usuario publique aplicaciones propias o de terceros
- No hay control sobre la infraestructura pero si sobre la aplicaciones

Infraestructura como servicio (IaaS, Infrastructure As A Service)

- Se dispone de infraestructura de computación como un servicio, usando virtualización
- El cliente compra recursos para hosting, capacidad de cómputo, redes, entre otras
- No hay control directo sobre la infraestructura, pero si se puede controlar el sistema operativo

Cloud Computing – Otros Servicios

Escritorio como servicio (Daas, Desktop as a Service)

- Escritorios virtuales alojados en la nube por un proveedor cloud.

Big Data como servicio (BDaaS, Big Data as a Services)

- Servicios que ofrecen análisis de conjuntos de datos grandes o complejos, utilizando los servicios alojados en la nube.

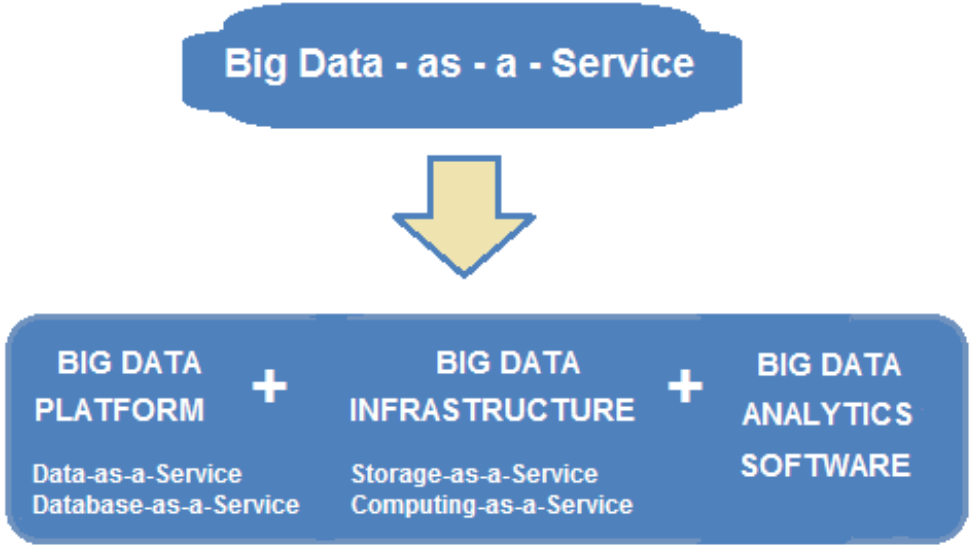

http://ivyproschool.com/blog/2015/01/14/big-data-as-a-service-bdaas-an-emerging-trend-of-2015/

Cuadrante Mágico de Gartner: Servicios estratégicos de plataforma en la nube

https://aws.amazon.com/es/blogs/aws/aws-named-as-a-leader-in-2025-gartner-magic-quadrant-for-strategic-cloud-platform-services-for-15-years-in-a-row/

AWS Services

Deployment & Management

Application Services
Amazon SQS
Amazon ElasticTranscoder
Amazon SES
Amazon AppStream
Amazon CloudSearch

Mobile Services
Amazon Cognito
Amazon Mobile Analytics
Amazon SNS

Enterprise Applications
Amazon WorkDocs
Amazon WorkSpaces
Amazon WorkMail

Application Services

Administration & Security
AWS DirectoryService
AWS AWSIAM
AWS Trusted Advisor
AWS Config
AWS CloudTrail
Amazon CloudWatch

Deployment & Management
Amazon CloudFormation
AWS OpsWorks
AWS CodeDeploy

Analytics
Amazon Kinesis
AWS Data Pipeline
Amazon EMR

Foundation Services

Compute
Amazon EC2
AWS Lambda

Storage & Content Delivery
Amazon CloudFront
Amazon Glacier
AWS Storage Gateway
Amazon Content Delivery

Database
Amazon Dynamo DB
Amazon RDS
Amazon Redshift
Amazon Elastic Cache

Networking
Amazon Route 53
Amazon VPC
AWS Direct Conect

https://aws.amazon.com/es/

Google Cloud Platform

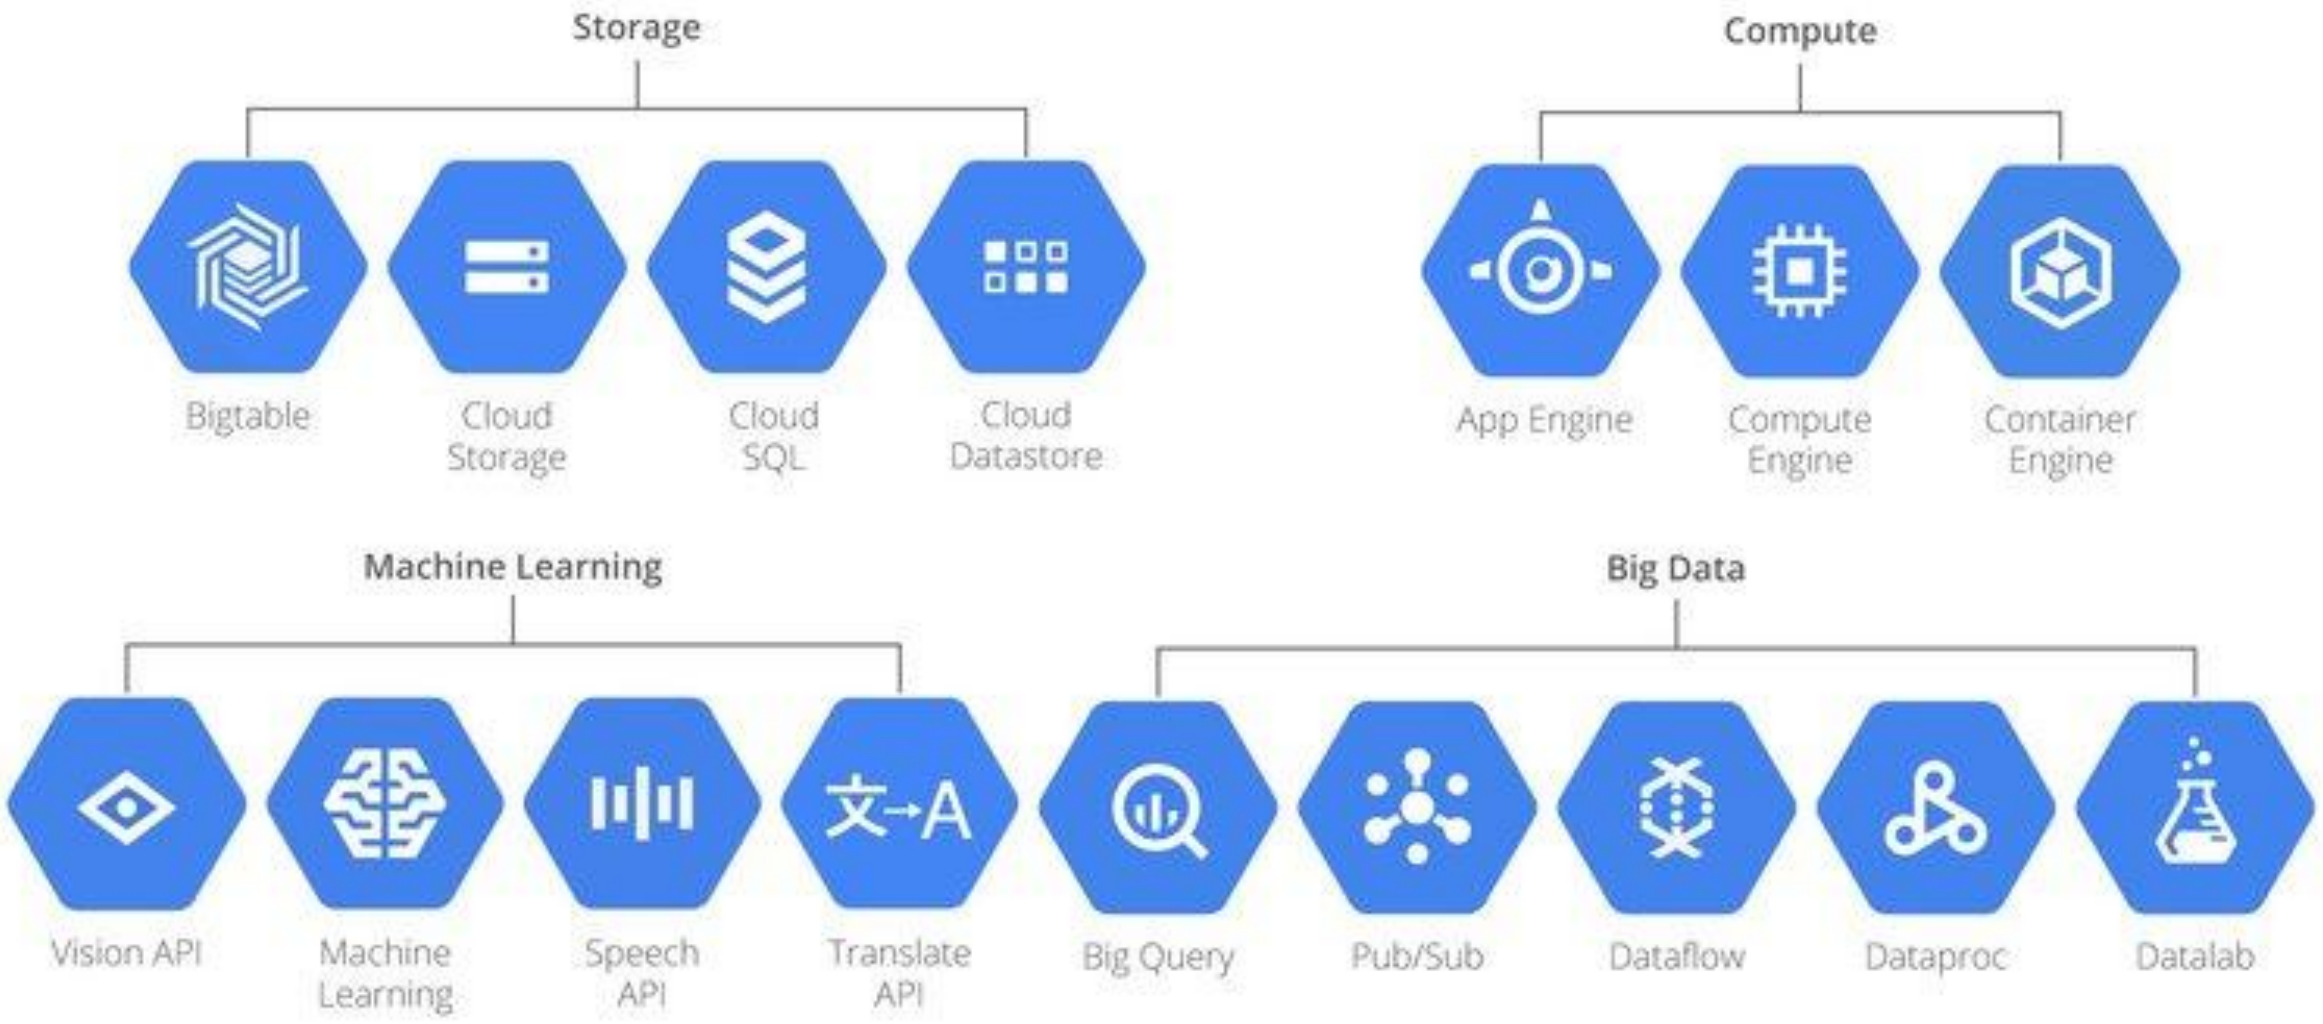

https://cloud.google.com/

Microsoft Azure

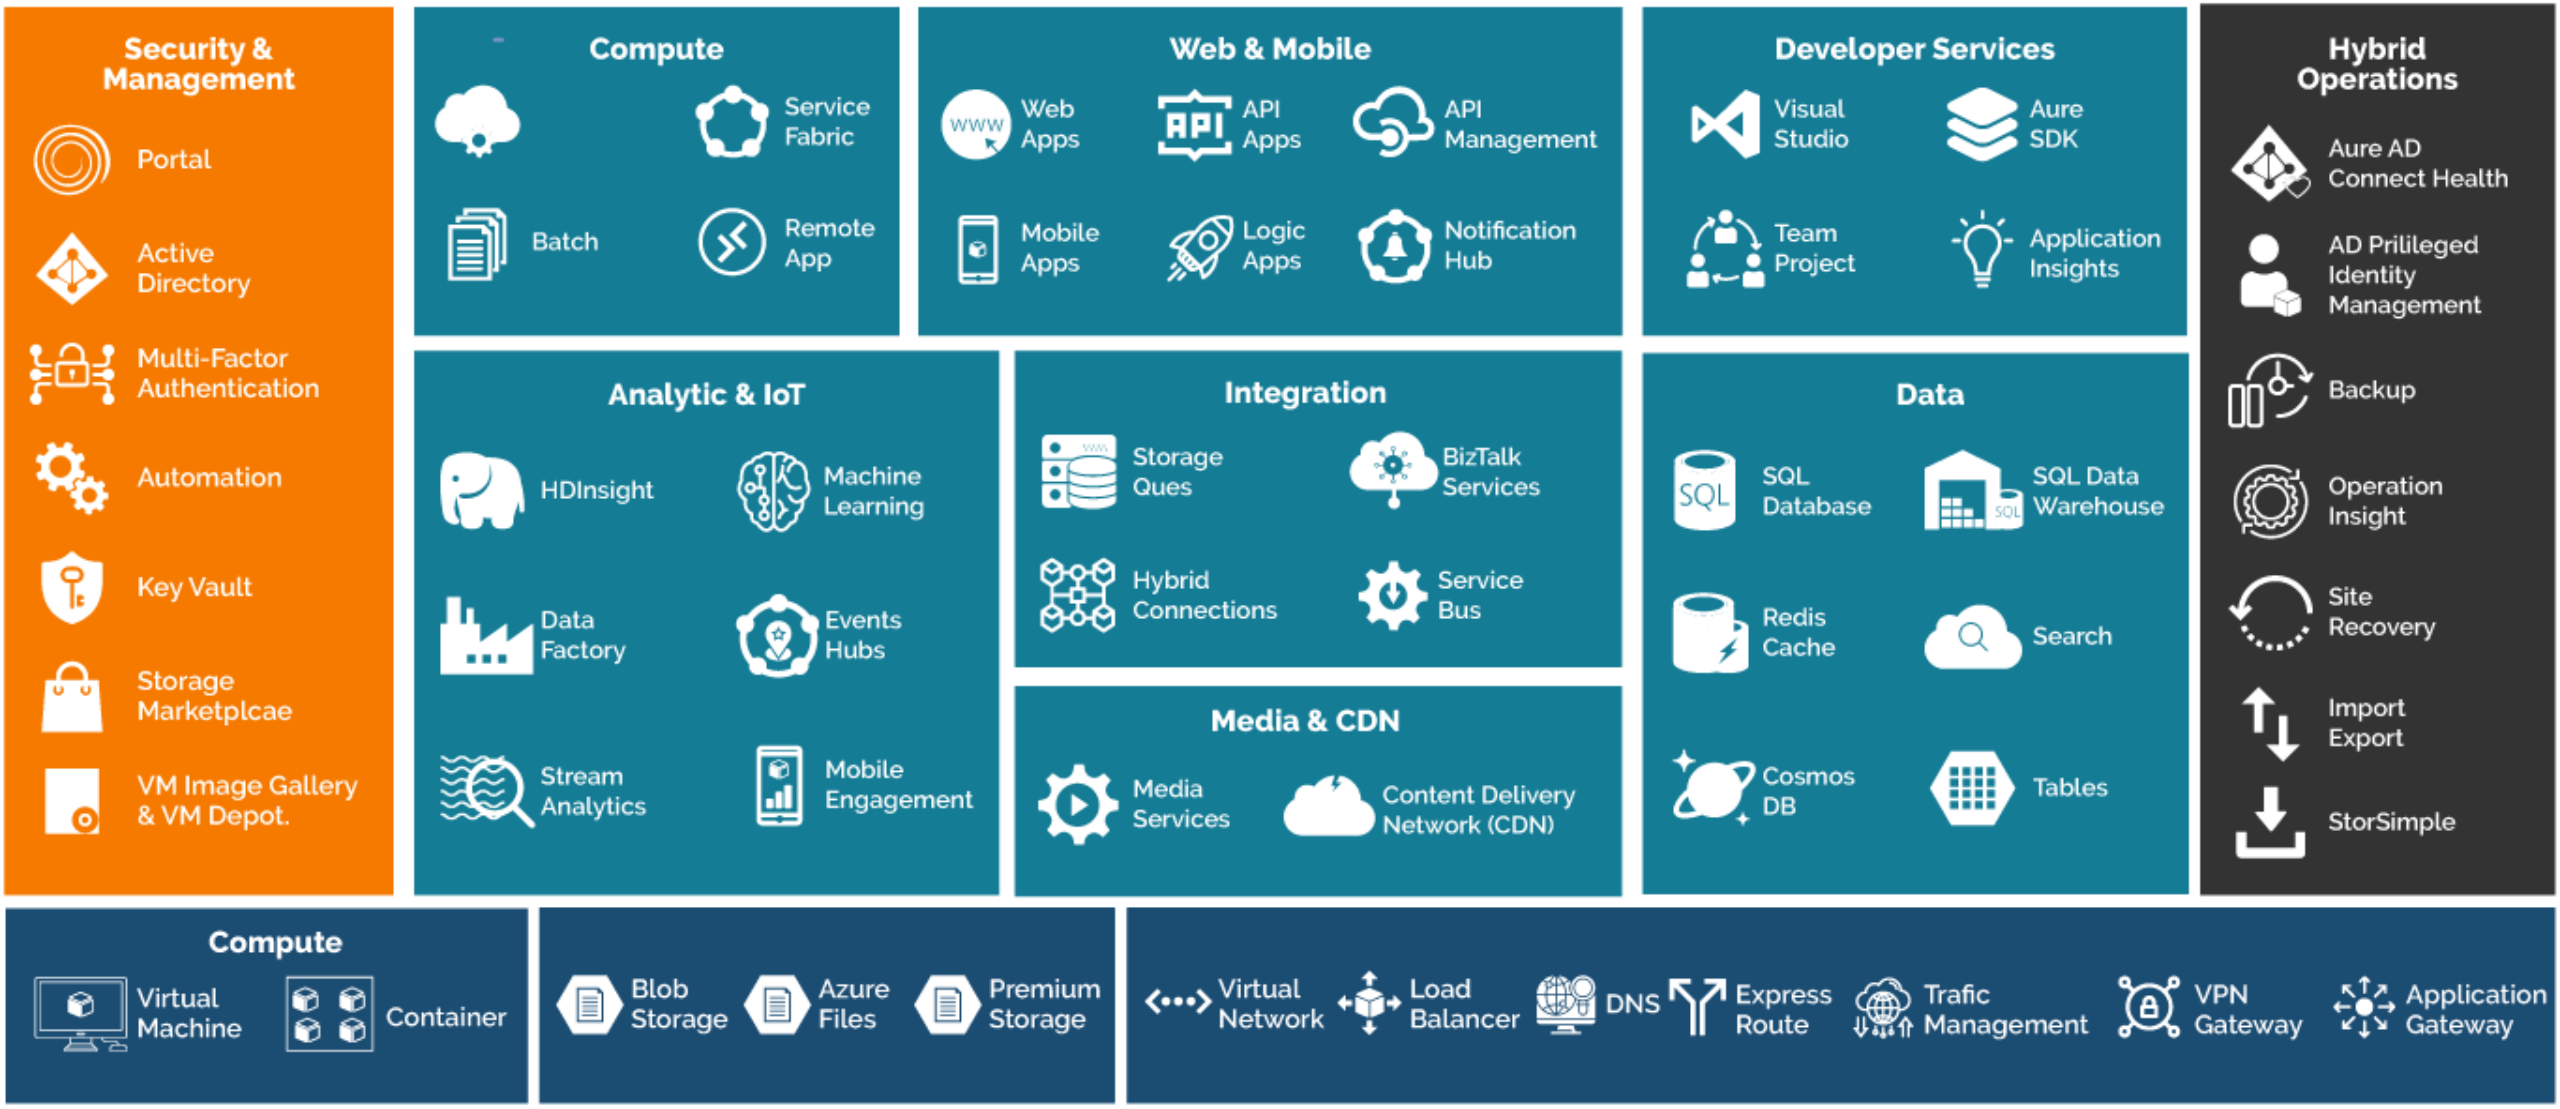

https://azure.microsoft.com/es-es/

Equivalencias entre servicios Cloud

Función	AWS	Google Cloud	Azure
Cómputo (VM)	EC2	Compute Engine	Virtual Machines
Almacenamiento de objetos	S3	Cloud Storage	Blob Storage
Red virtual	VPC	VPC	Virtual Network
Ingesta de eventos	Kinesis Data Streams	Pub/Sub	Event Hubs
Procesamiento en tiempo real	Lambda, Kinesis Analytics	Dataflow	Stream Analytics
Serverless	Lambda	Cloud Functions	Azure Functions

AGENDA

UdeA
Analytics & DataScience

1. Contexto
2. Procesamiento de Datos
3. Cloud Computing
4. **Aplicaciones**

Aplicaciones

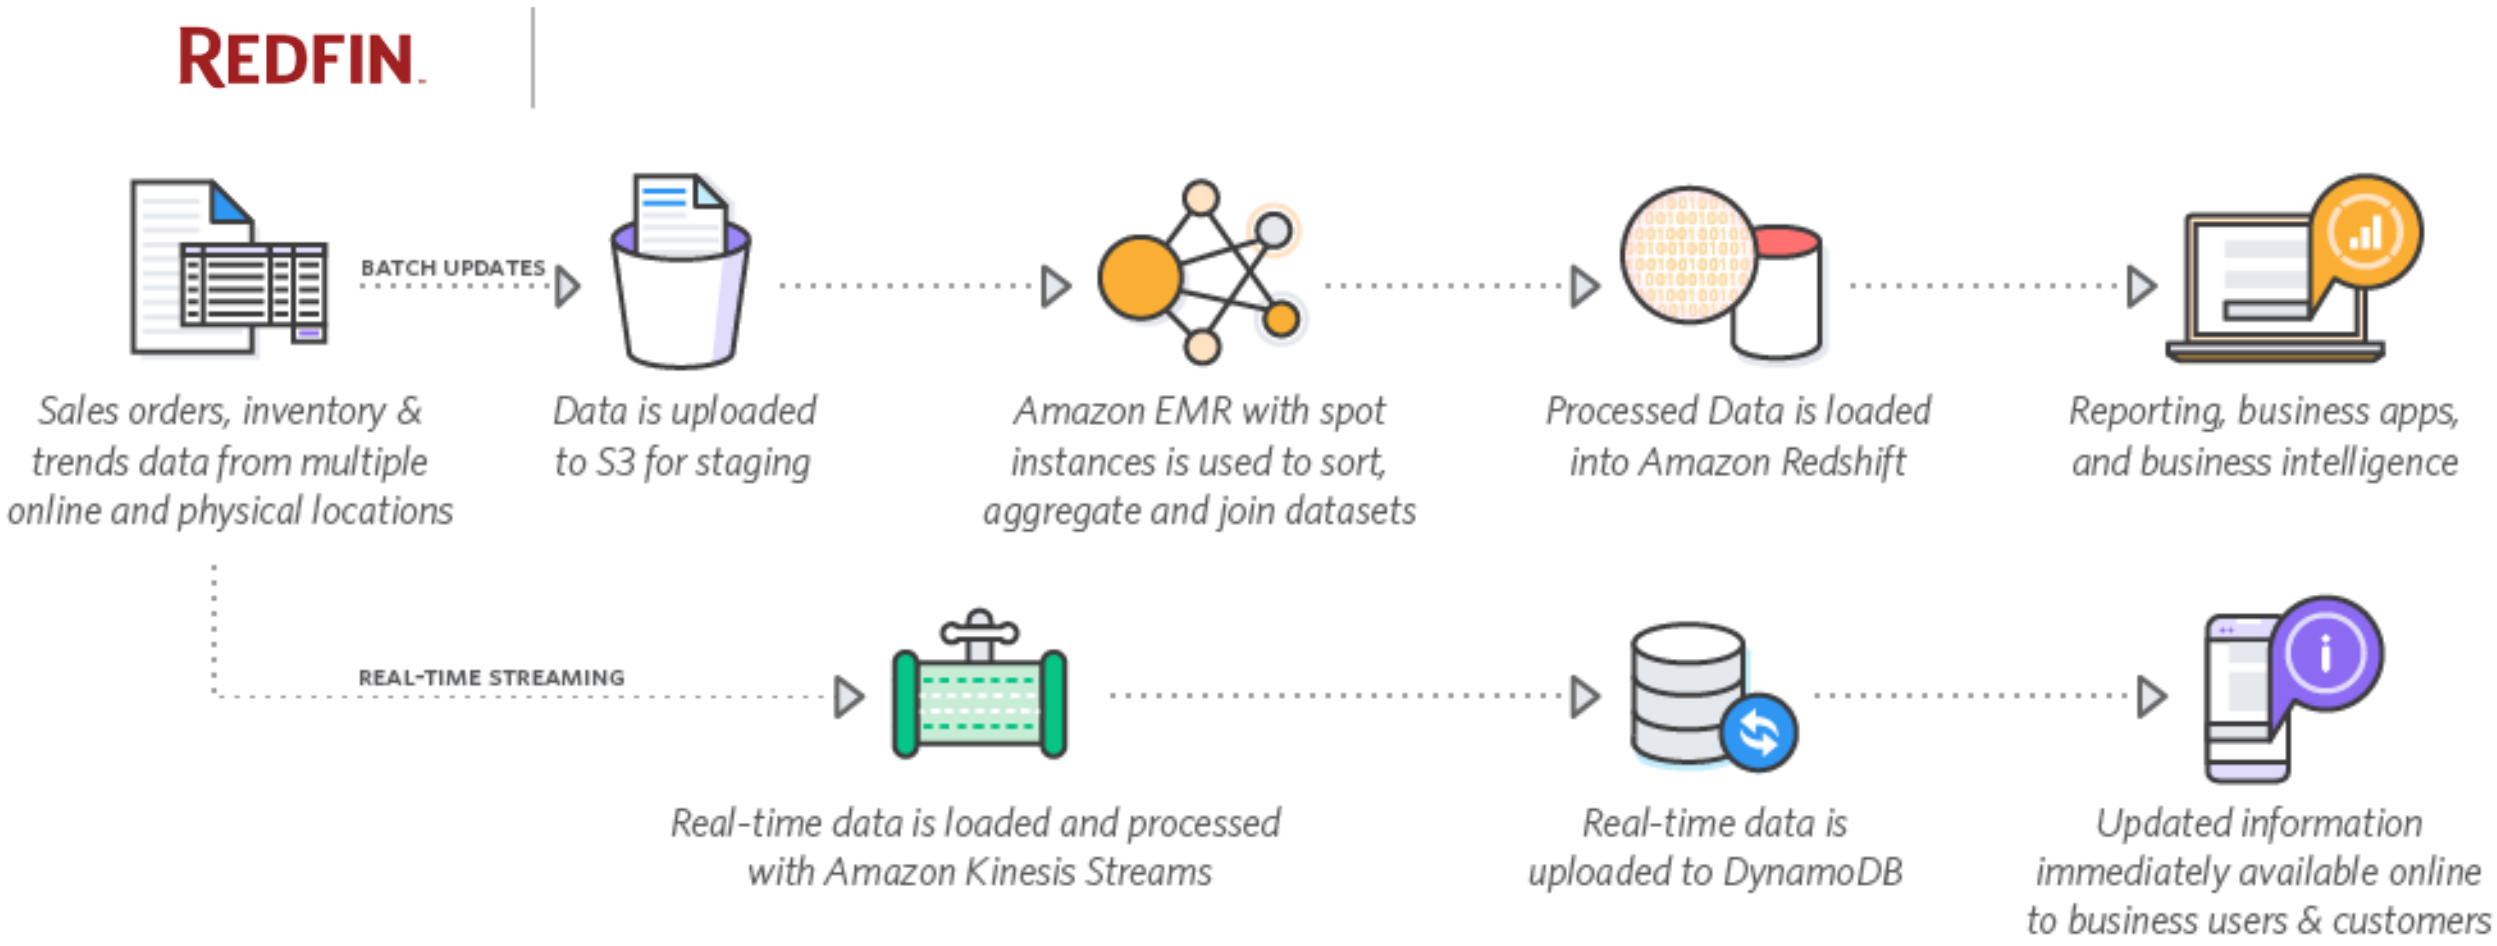

https://aws.amazon.com/es/solutions/case-studies/redfin/

Aplicaciones

HEARST corporation

Send clickstream data to Kinesis Streams

Kinesis Streams stores and exposes clickstream data for processing

Custom application built on Kinesis Client Library makes real-time content recommendations

Readers see personalized content suggestions

https://aws.amazon.com/es/solutions/case-studies/hearst/

Aplicaciones

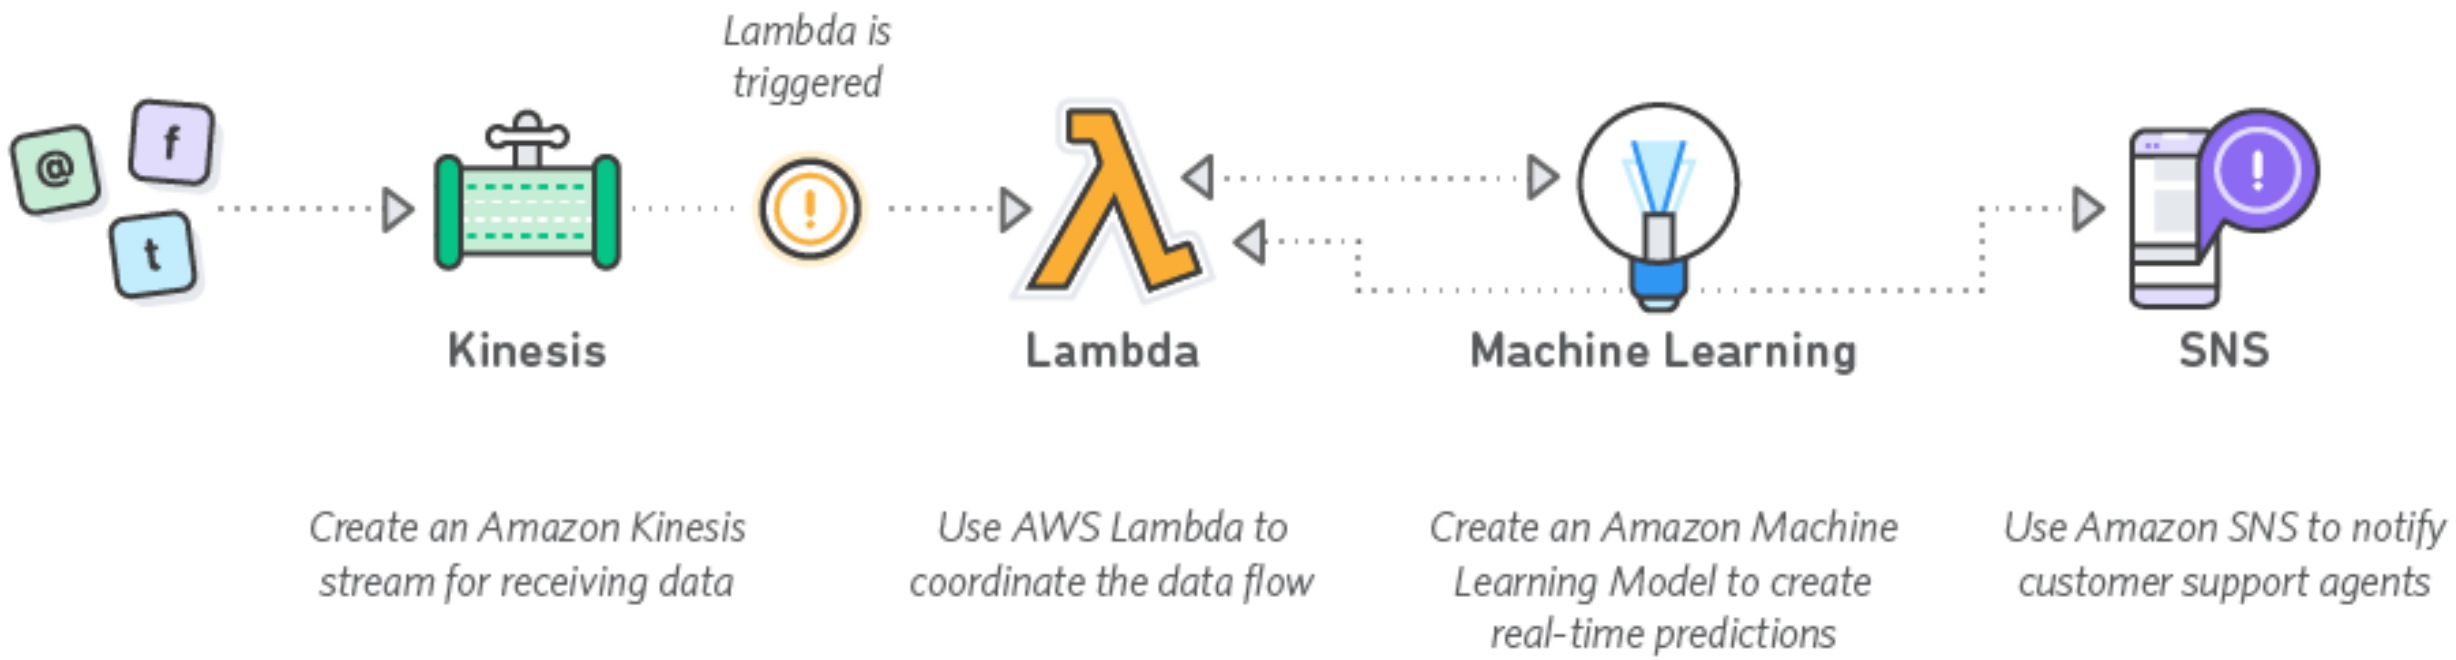

https://aws.amazon.com/es/solutions/case-studies/buildfax/

Aplicaciones

https://customers.microsoft.com/es-es/story/1423193863644293457-nba-media-entertainment-azure-es-xl

https://customers.microsoft.com/es-es/story/1473578443276306172-iberia-express-other-azure-es-spain

https://cloud.google.com/customers/ach-colombia/?hl=es-419

https://cloud.google.com/customers/auteco-mobility/?hl=es-419

https://cloud.google.com/customers/sodimac/?hl=es-419

https://cloud.google.com/customers/globo/?hl=es-419

Contenido

UdeA
Analytics & DataScience

Tema	Detalle
Introducción	Procesamiento de datos en Batch, Streaming y micro-batch. Data Lakes vs Data Steams Cloud Computing
Serialización de Datos	Serialización de Datos: Formatos tradicionales (JSON, XML, YAML), Formatos Optimizados (Protocol Bufer, Apache Thrift)
Procesamiento de datos	Procesamiento basado en eventos, Batch processing, Continuos Stream Processing, Servicios de Stream Processing
Servicios y Plataformas en la Nube (AWS)	Fundamentos: VPC, EC2, S3, Cloud9, Lambda. Escalabilidad: ALB, RDS Servicios de Stream Processing: Kinesis